Segmentez des clients d'un site e-commerce

Parcours Data Scientist financé par Pôle Emploi
Étudiante: Veronika BEREZHNAIA
Mentor: Gaëtan GOLLIOT
Évaluateur: Christian Noumsi

Problématique

- Je suis consultante pour Olist, un marketplace en ligne.
- Olist souhaite que je fournisse à ses équipes d'e-commerce une segmentation des clients qu’elles pourront utiliser au quotidien pour leurs campagnes de communication.
- Je dois fournir à l’équipe marketing une description actionnable de ma segmentation, ainsi qu’une proposition de contrat de maintenance basée sur une analyse de la stabilité des segments au cours du temps.

Ma mission :

- La segmentation proposée doit être exploitable et facile d’utilisation pour l’équipe marketing.
- J’evaluerai la fréquence à laquelle la segmentation doit être mise à jour, afin de pouvoir effectuer un devis de contrat de maintenance.

Sommaire

- Fusionner tous les tableaux pértinents :
  - Sélectionner des variables pertinents ;
  - Aggréger par client avec les bonnes fonctions
  - Création de nouvelles variables
- Tester des différents algorithmes de la segmentation
  - Sélection d'algorithmes
  - Sélection du meilleur écailleur (scaler, like StandardScaler or RobustScaler) et de meilleur nombre de segment pour KMeans
  - Sélection de bonnes métriques d'évaluation
  - Comparaison des modèles et de segments obtenus, leur interprétation et signification pour l'equipe d'Olist
- Stabilité temporelle
  - Assurer la cohérence avec random states différents de modèle (pour Kmeans)
  - Comparer la stabilité temporelle pour plusieurs modèles/variétés de modèle
  - Comparer la stabilité temporelle pour la fenêtre en expansion et la fenêtre glissante

Fusionner les tableaux

- Ordres :
  - Nombre d'ordres ;
  - Temps moyen de livraison
  - Le retard moyen de la livraison
  - La semaine ou le mois de l'année préféré (pour identifier les clients de pic de Noël)
  - **Fréquence**
  - **Récence**

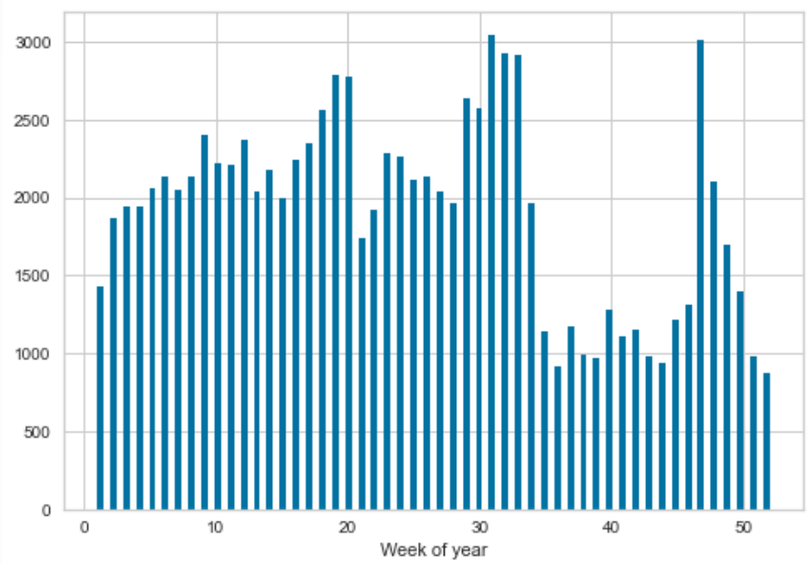

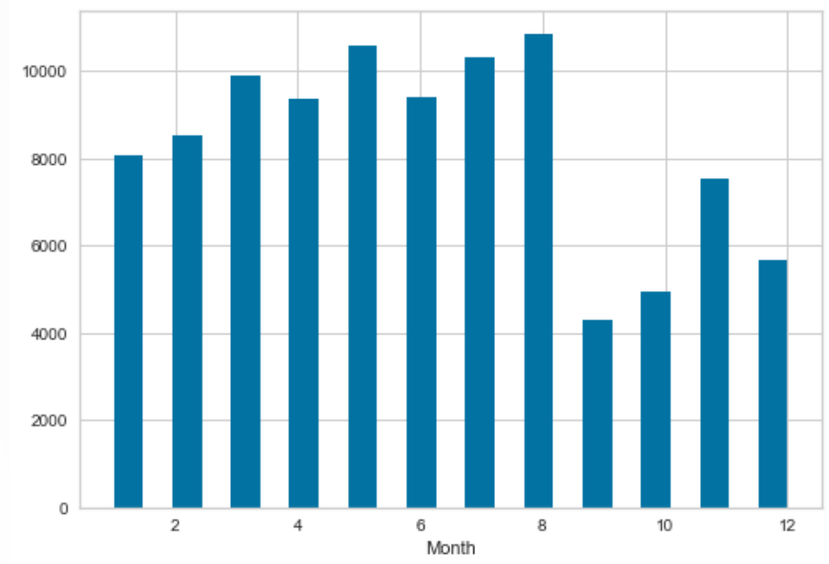

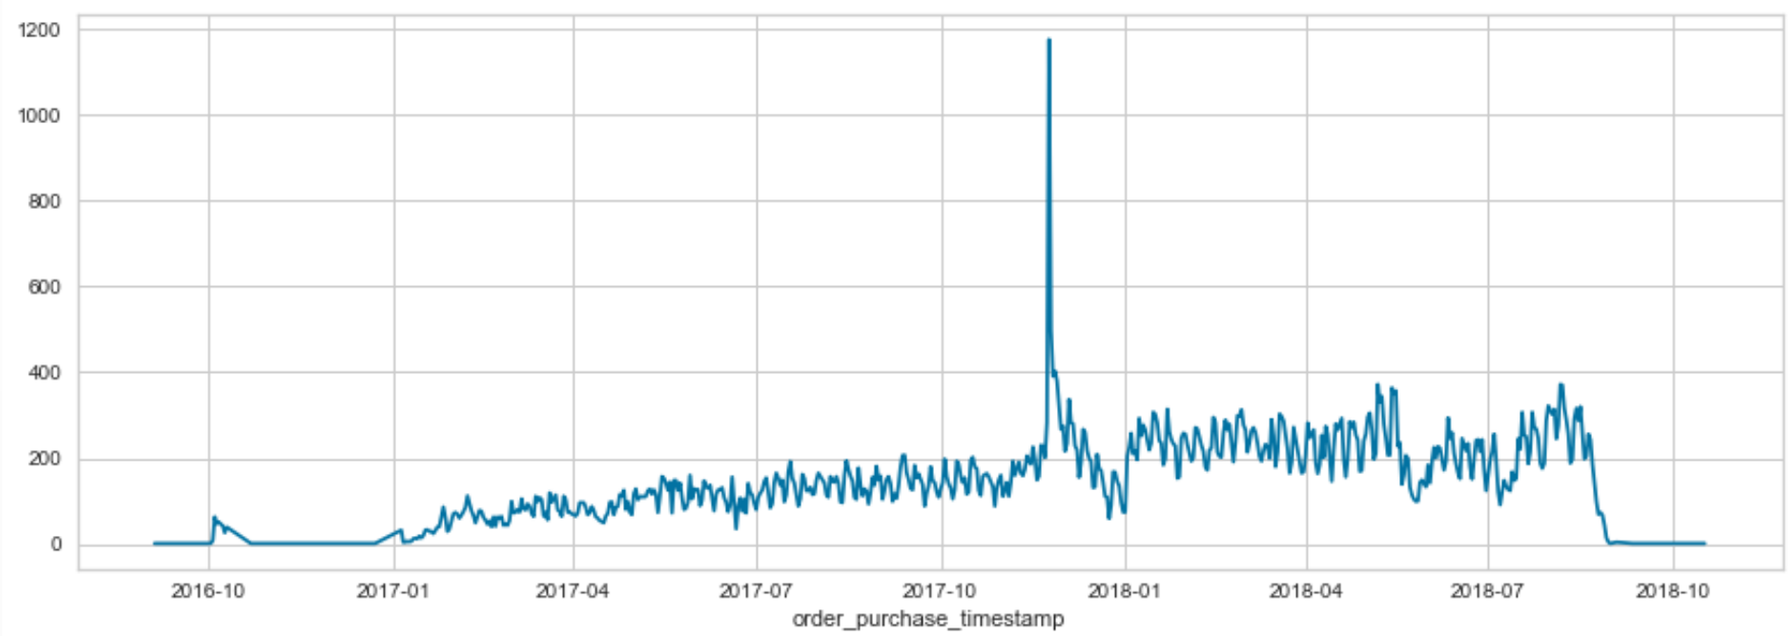

Fusionner les tableaux

- Items (objets):
  - Nombre d'objets par ordre
  - **Prix moyen d'objet**
  - **Prix moyen d'ordre**
  - **Prix totale**
  - Ratio Frais de livraison/Prix
- Paiements:
  - Paiement moyen
  - **Paiement total**
  - Nombre de crédits
  - Nombre de bons de réduction utilisés
- <u>Avis moyen du client</u>
- Infos sur les produits achetés par client :
  - Catégorie de produit
  - Quantité de photos
  - Longueur de la description
  - Poids
- Localisation de client
  - Distance euclidienne entre le client et le siège d'Olist
  - Distance euclidienne entre le centre d'état du client et la siège d'Olist

Préparations finales

- Remplir des valeurs manquantes, filtrer les variables ayants des correlations linéaires
- La liste finale des variables :
  - **Nombre d'ordres**,
  - **Objets par ordre**,
  - Delais de livraison,
  - Mois de l'année (correlant avec la semaine de l'année),
  - **Fréquence**,
  - **Récence**,
  - **Prix moyen d'un objet**,
  - Prix totale, **payment total**,
  - Nombre de paiements par ordre (corrélant avec le nombre de bons de réduction utilisés),
  - **Nombre de crédits**,
  - **L'avis moyen du client**,
  - Proportion frais de transport/prix,
  - Distance jusqu'au client (correlant avec distance jusqu'au centroïde d'état du client)

Segmentation : KMeans

- Sélection des clusters sphériques
- Sensible à la méthode de mise à l'echelle / écailleur (MinMaxScaler ou StandardScaler)
- Avec StandardScaler, les segments ont du sens, mais la visualisation de Silhouettes montre qu'il y a nombre important de clients attribués au mauvais segments.
- Pour résoudre ce soucis, j'ai testé deux approches :
  - Reduire encore le nombre de variables (jusqu'aux 8 variablés essentielles)
  - Utiliser un autre écailleur (RobustScaler ou MinMaxScaler)

Analyse en composants principals, réduction dimensionnelle

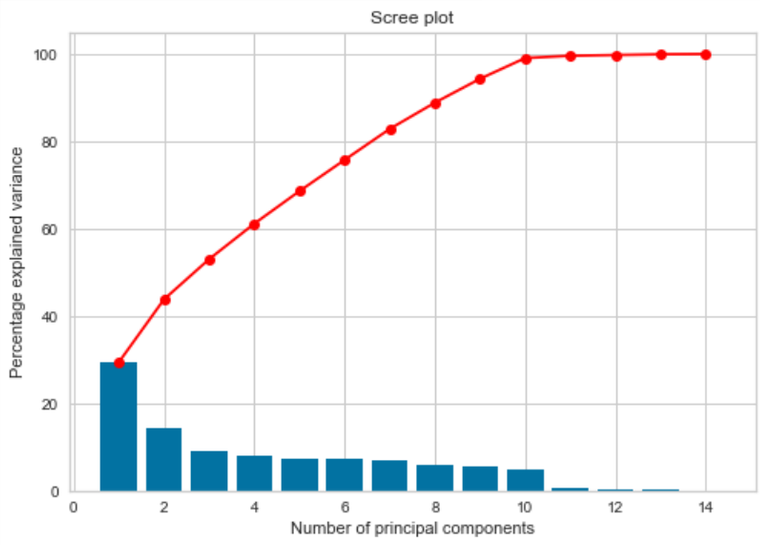

Standard scaler

MinMax scaler

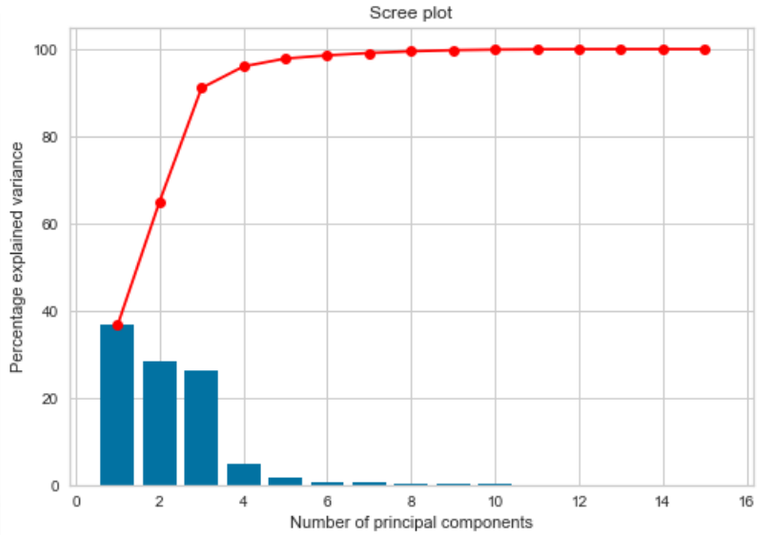

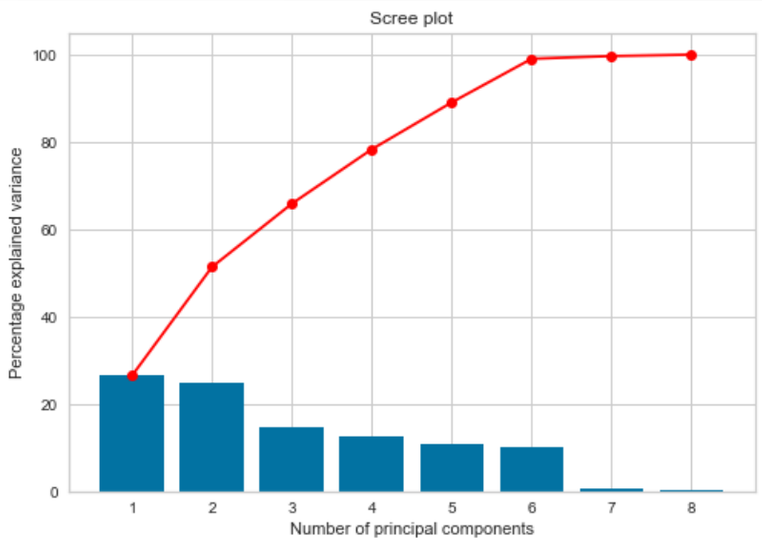

Standard scaler, reduced set

Sélection de nombre de K en KMeans

Original

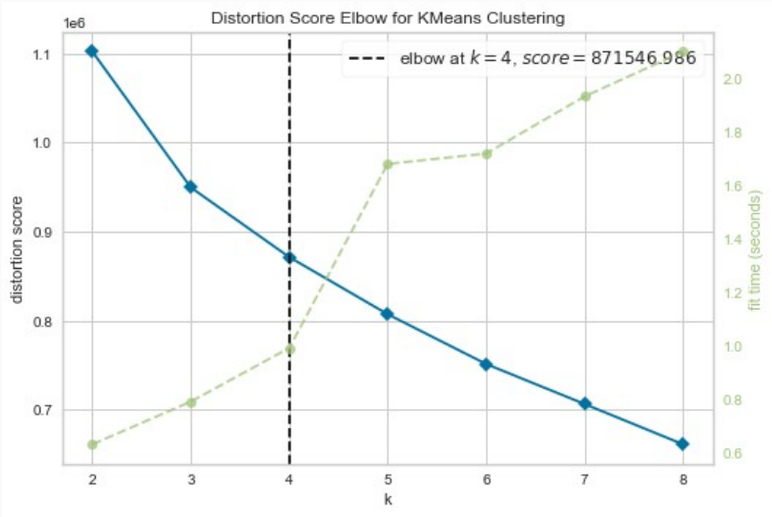

StandardScaler,
Full set of variables

Original

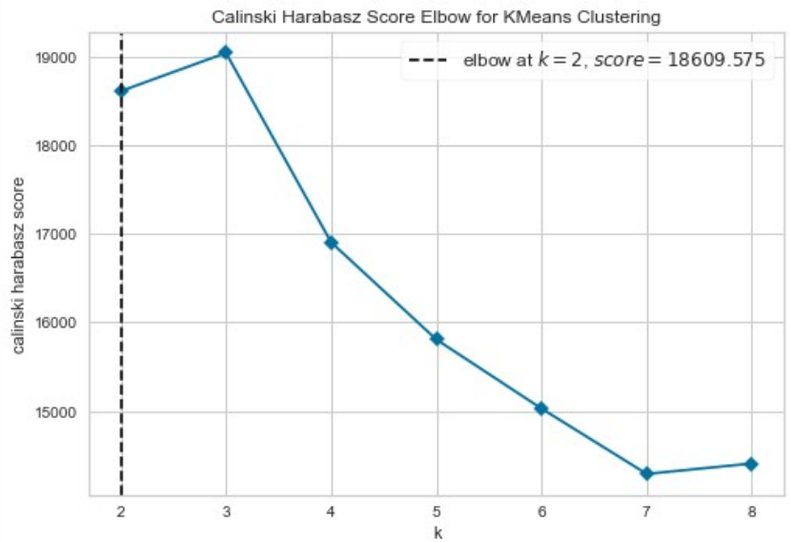

PCA projected

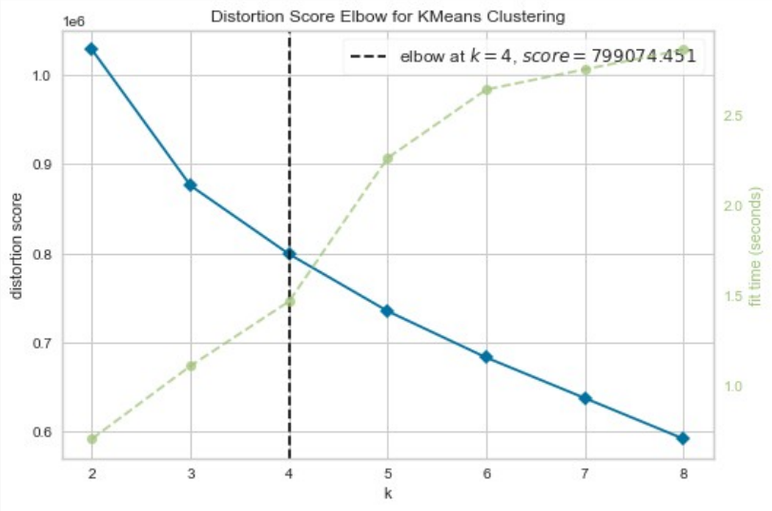

PCA projected

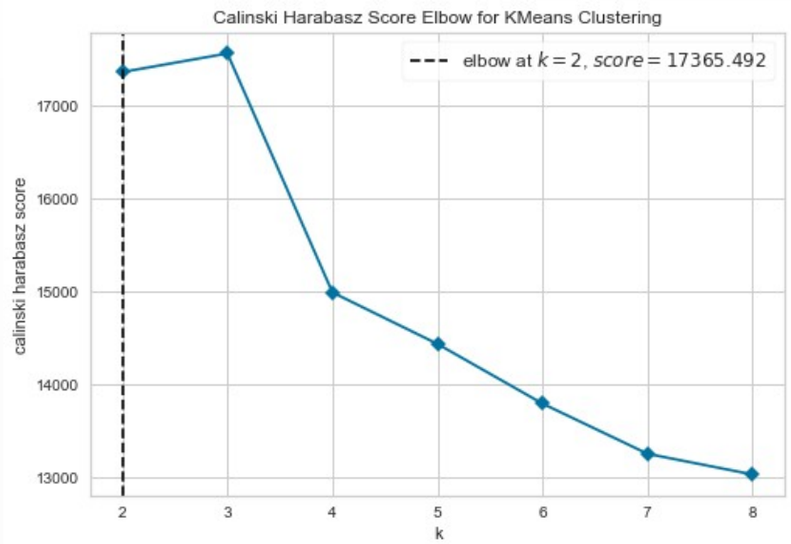

Metriques

Original

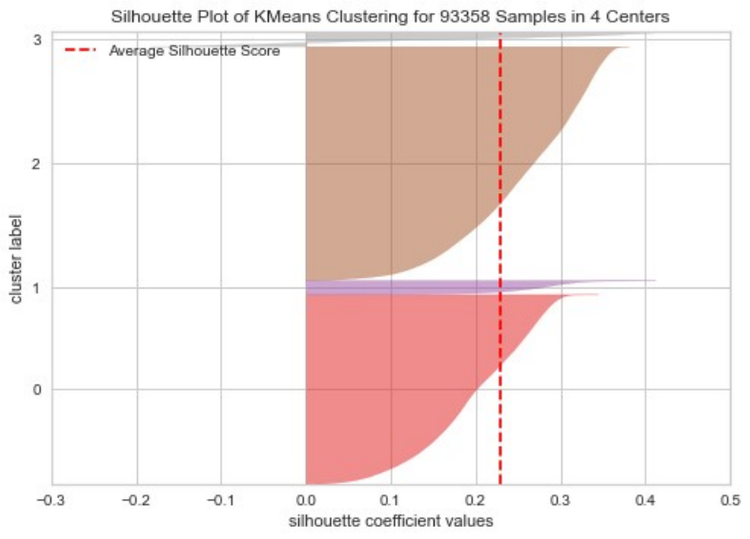

0	48224
1	39159
2	3053
3	2922

Original

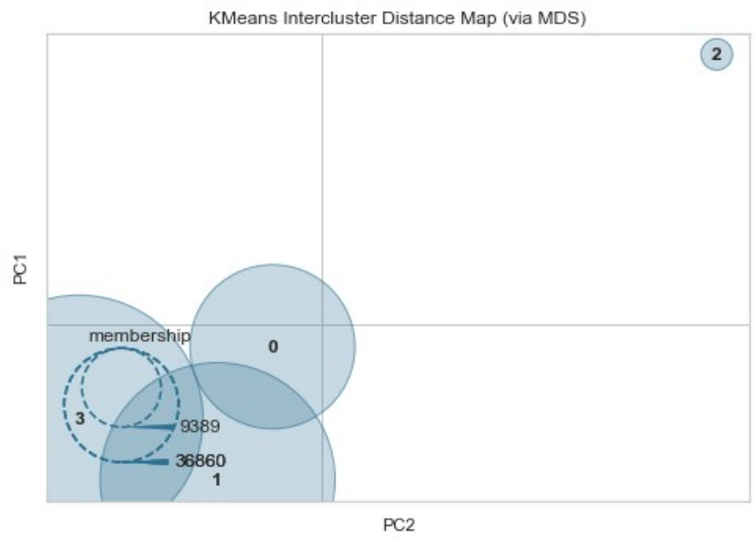

PCA projected (pas besoin de passer par PCA)

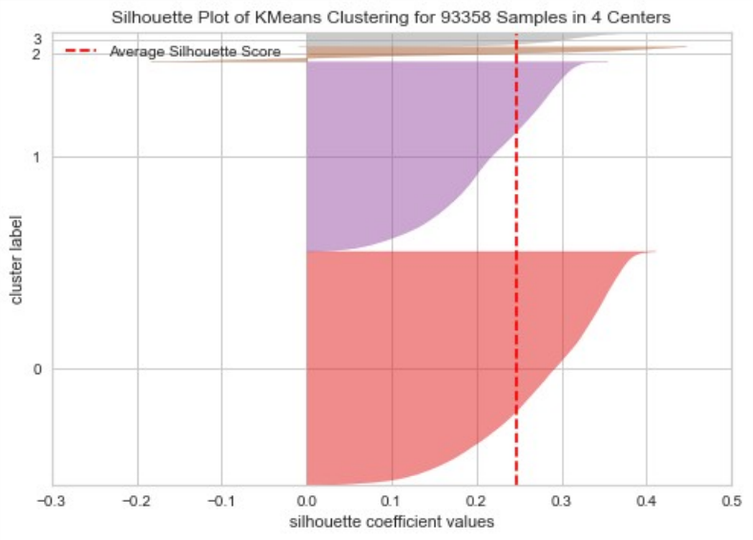

1	48225
0	39157
2	3047
3	2929

PCA projected

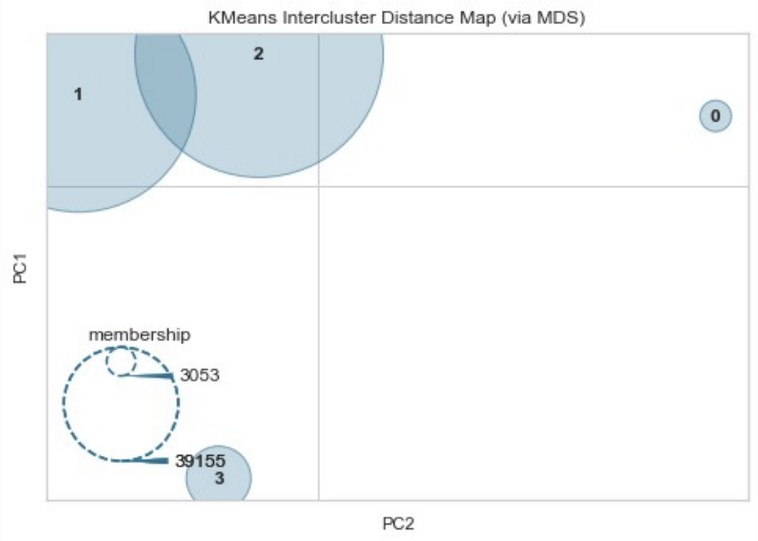

Signification de segments

Original et PCA projected
ont les mêmes paramètres

Les traits distinctives
des membres de chaque segment
sont présentées
dans le diapositif suivant

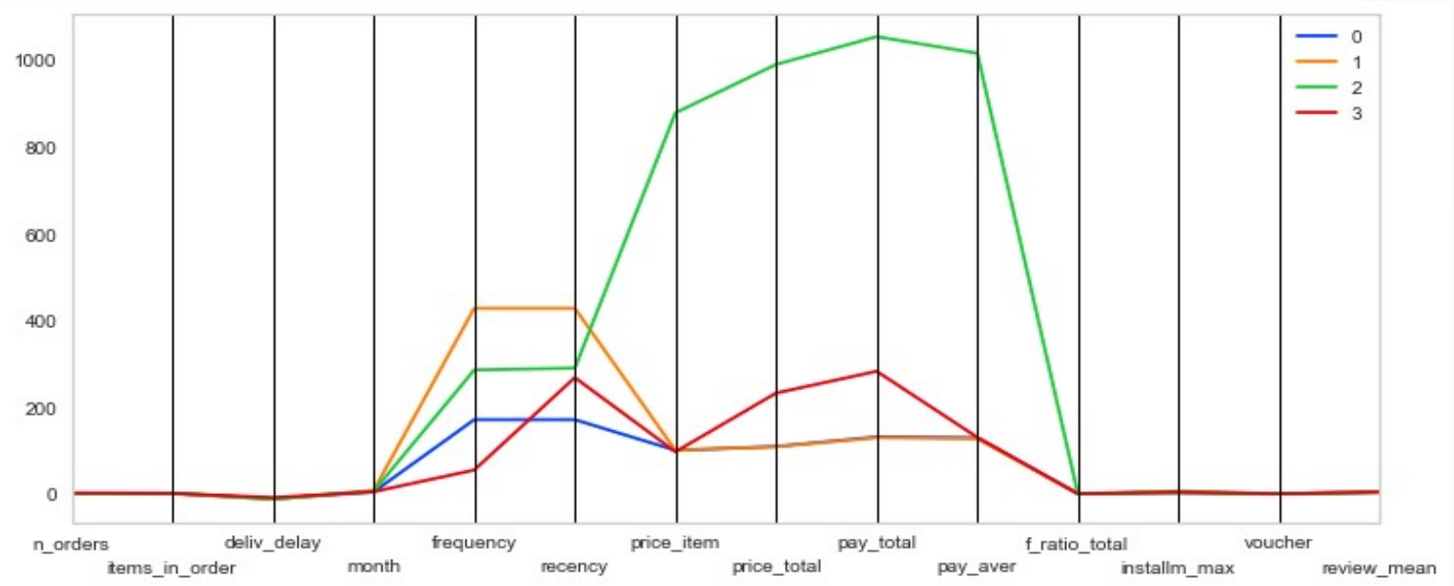

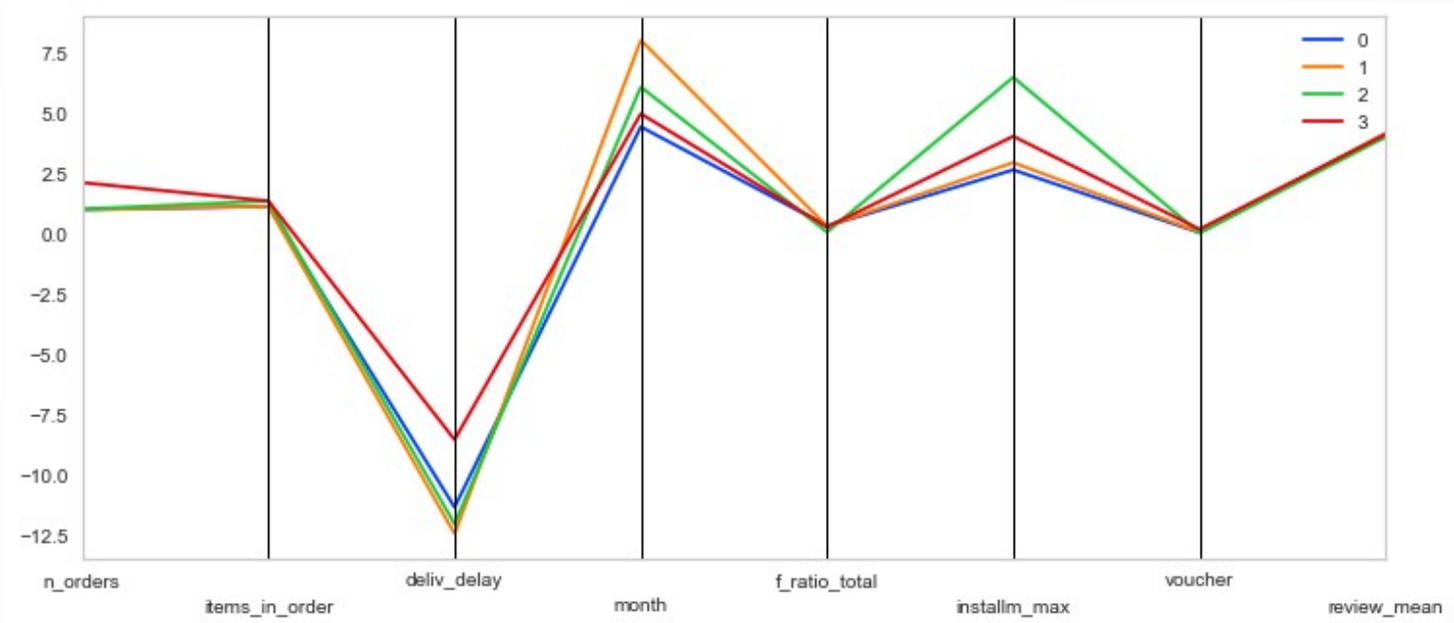

Signification des segments

- 0 : Clients **relativement recents**, qui avaient visité le sité il y a 150 jours. Ils achètent des articles au prix pas excessif, 130 euros. Ils ont depensé pas beaucoup, en moyen 150 réals brésiliens.
- 1 : Clients **anciens et rares**, plus de 400 jours. Ils achètent des articles au prix pas excessif, 130 euros. Ils ont depensé pas beaucoup, en moyen 150 réals brésiliens.
- 2 : Clients d'ancienneté moyenne, en moyen 300 jours. **Depenseurs de grandes sommes, ils achètent des articles cheres**, et payent en grandes sommes (ne prennent pas ou prennent peu de bons de réduction). Ils ont tendance à payer **des acomptes**.
- 3 : **Clients dormants : fréquents**(moins de 100 jours de pause), **mais anciennes**. Ils ont dépensés des sommes un peu plus importants, environ 200 euros). Leur **retards de livraison sont plus grands** que pour autres segments (-8 jours contre -13).

Sélection de nombre de K en KMeans

Before PCA transform

StandardScaler,reduced set of variables

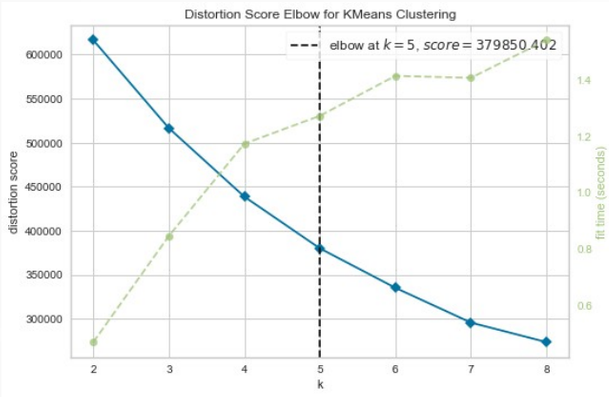

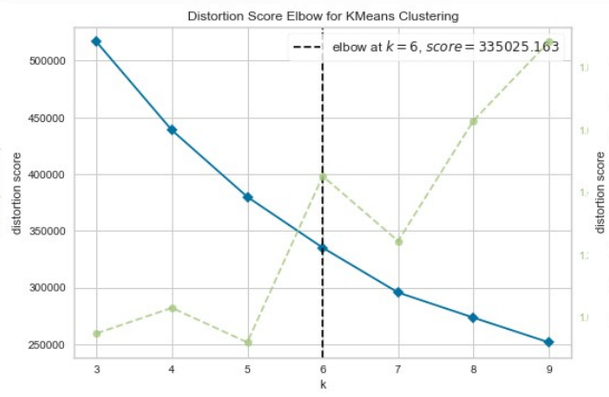

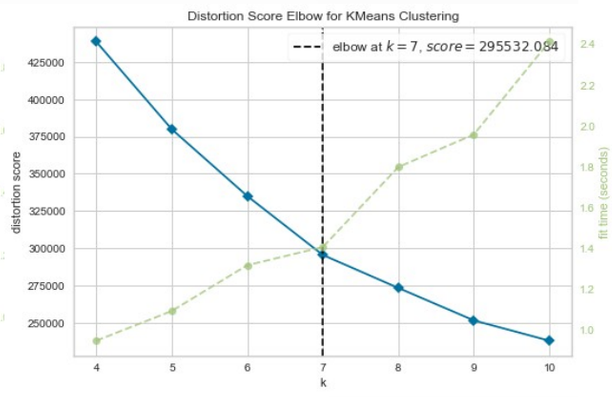

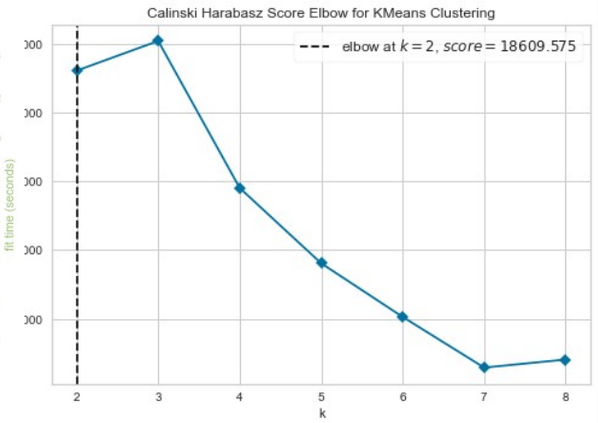

PCA projected – le même résultat : elbow value depend de limits initialement posés sur de graphiques

- n_orders,
- n_objets dans un ordre,
- Fréquence,
- Récence,
- Prix moyen d'objet,
- Paiement total,
- n_acomptes

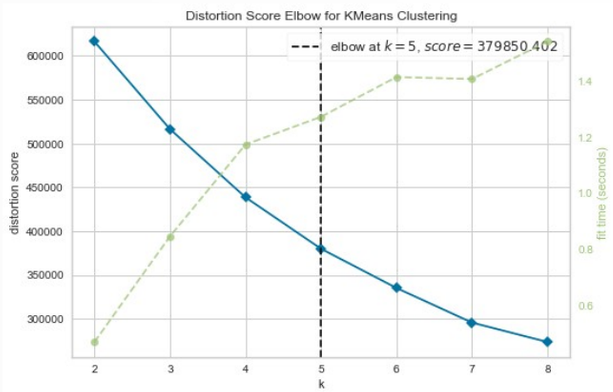

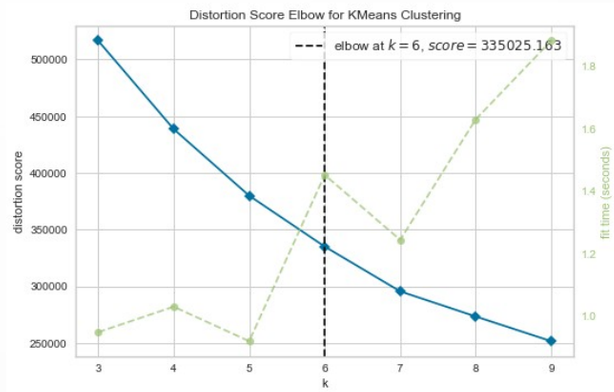

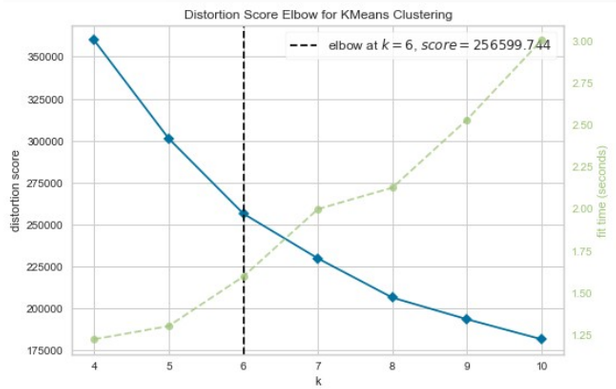

Metriques

Original

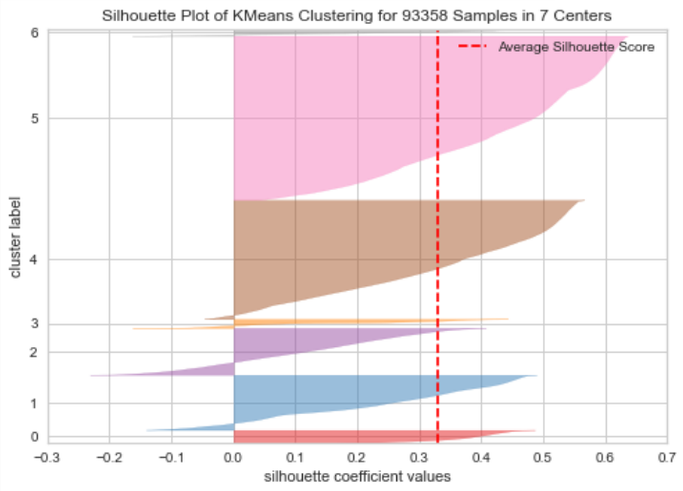

0	37083
4	26867
2	12441
5	10572
6	2880
3	2027
1	1488

Original

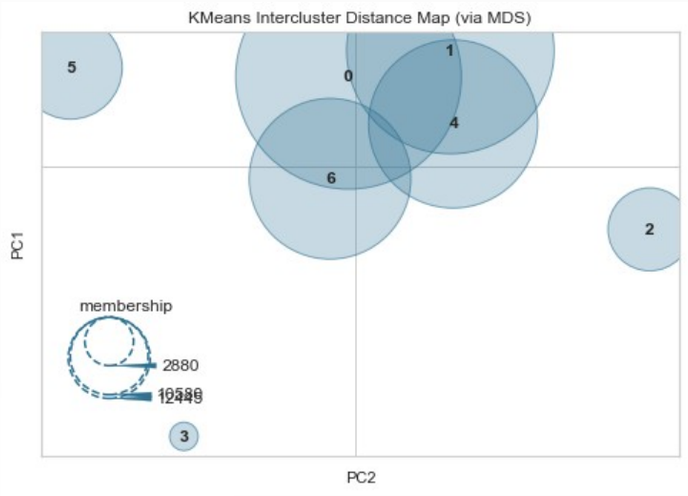

PCA projected (pas besoin de passer par PCA)

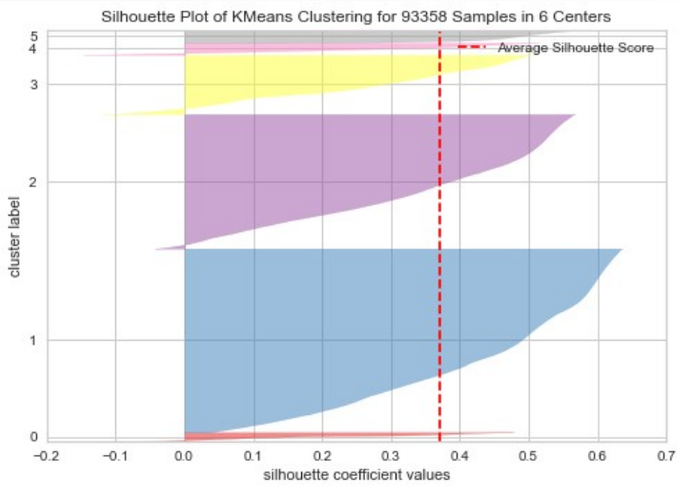

0	41687
3	30586
2	13453
4	2881
5	2722
1	2029

PCA projected

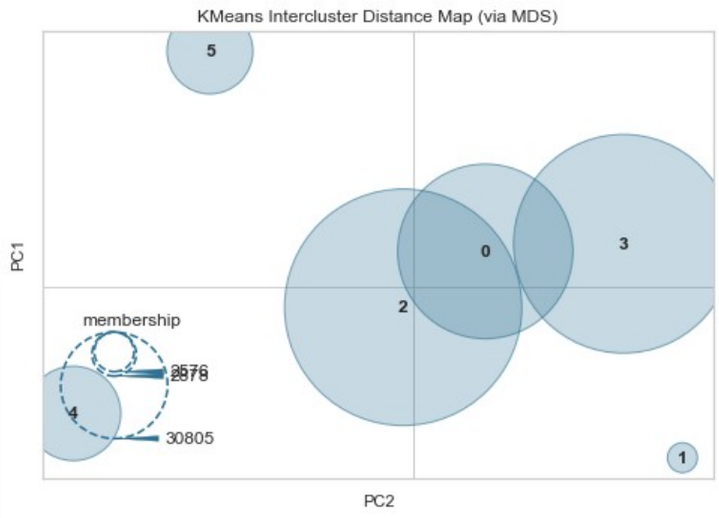

Signification de segments

PCA projected a des segments
moins actionnables

Les traits distinctives
des membres de chaque segment
sont présentées
dans le diapositif suivant

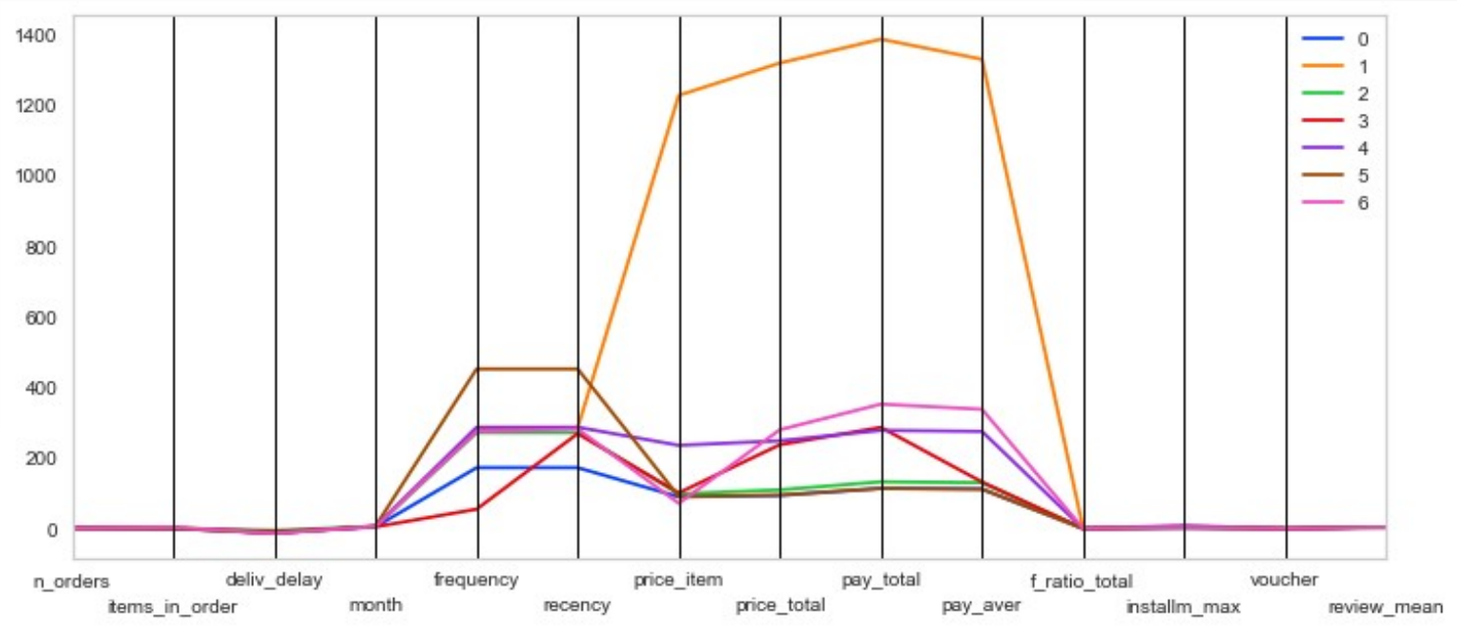

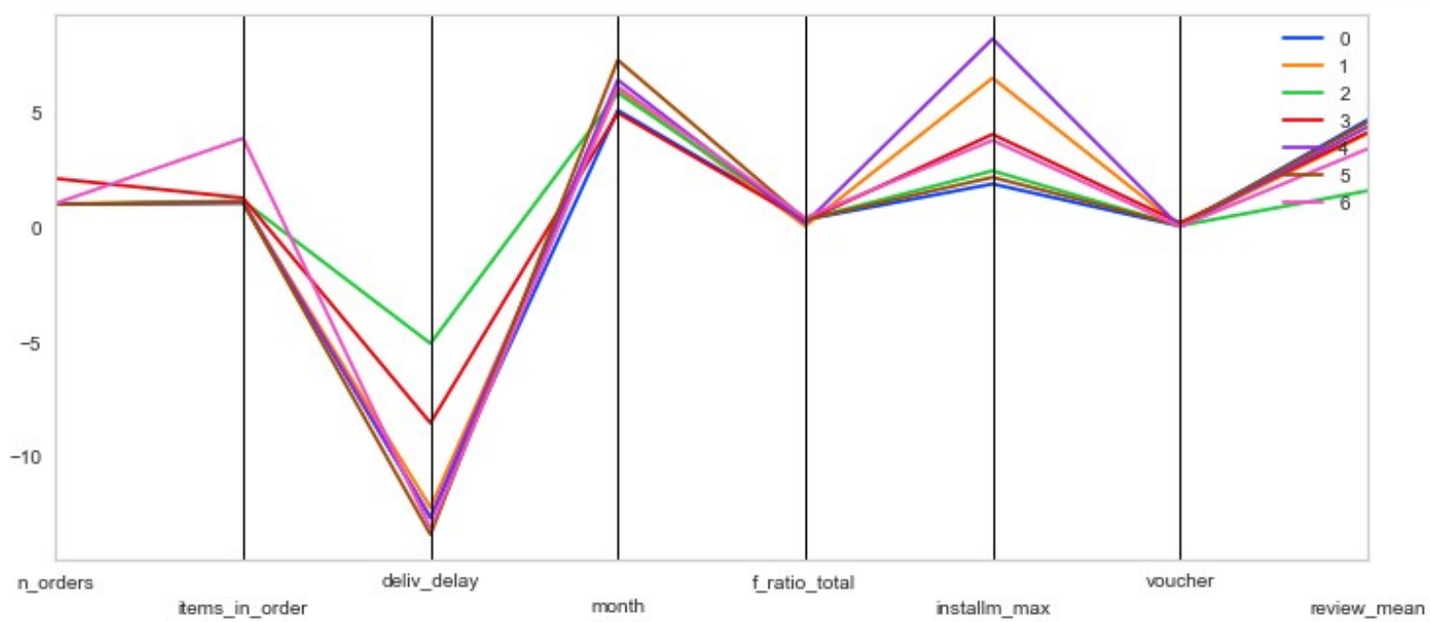

Signification des segments

- 0 : Clients **relativement recents**, qui avaient visité le sité il y a 150 jours. Ils achètent des articles au prix pas excessif, 130 euros. Ils ont depensé pas beaucoup, en moyen 150 réals brésiliens.
- 1 :**Clients dormants : fréquents**(moins de 100 jours de pause), **mais anciennes**. **Depenseurs de très grandes sommes, ils achètent des articles cheres**, et payent en grandes sommes (ne prennent pas ou prennent peu de bons de réduction). Ils ont tendance à prendre **des acomptes**, payer en plusieurs fois.
- 2 : Des clients d'ancienneté moyenne, de petites dépenses (environs 100 réals) et **l'avis clients bas**. Leur **retards de livraison sont plus grands** que pour autres segments (-5 jours contre -16).
- 3 : **Clients dormants : fréquents**(moins de 100 jours de pause), **mais anciennes**. Ils ont dépensés des sommes un peu plus importants, que dans les autres segments, environ 200 euros. Leur **retards de livraison sont plus grands** que pour autres segments (-9 jours contre -16).
- 4 : Des clients optants pour **les acomptes**. Ils achètent des objets **plus chères** que dans autres segments (280 euros contre 140), ils n'utilisent pas de bons de réduction.
- 5 : Clients **anciens et rares**, plus de 400 jours. Ils achètent des articles au prix bas par rapport aux autres segments (100 euros).
- 6 : client qui font **les ordres contenant beaucoup d'articles**. Ils achètent des articles pas chers, comme autres segments, mais en total ils dépensent plus que les autres segments (320 contre 260).

Sélection de nombre de K en KMeans

Original

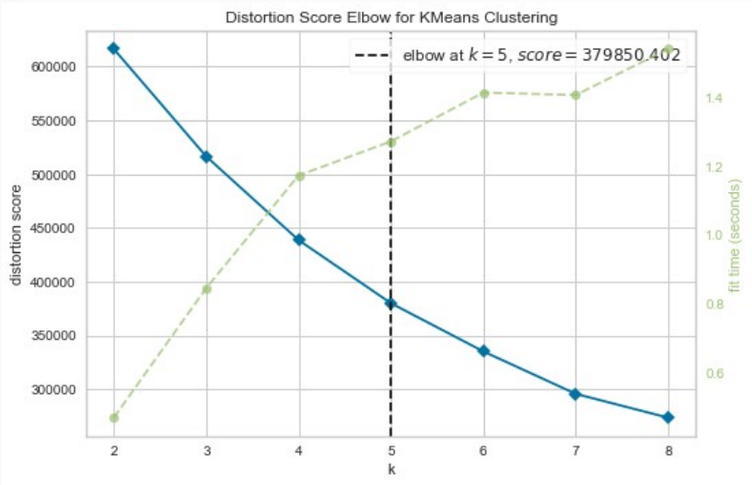

MinMaxScaler,
Full set of variables

Original

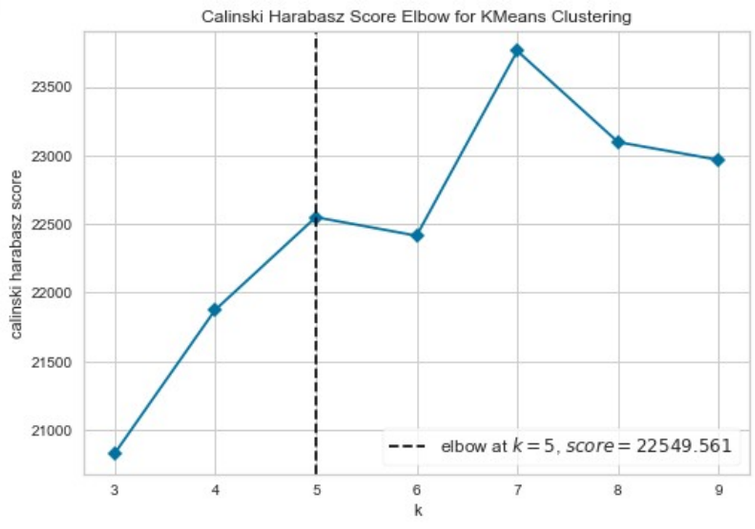

PCA projected

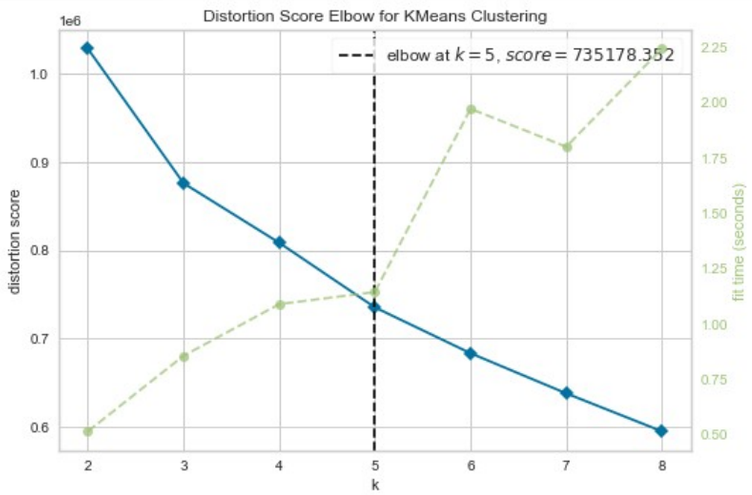

PCA projected

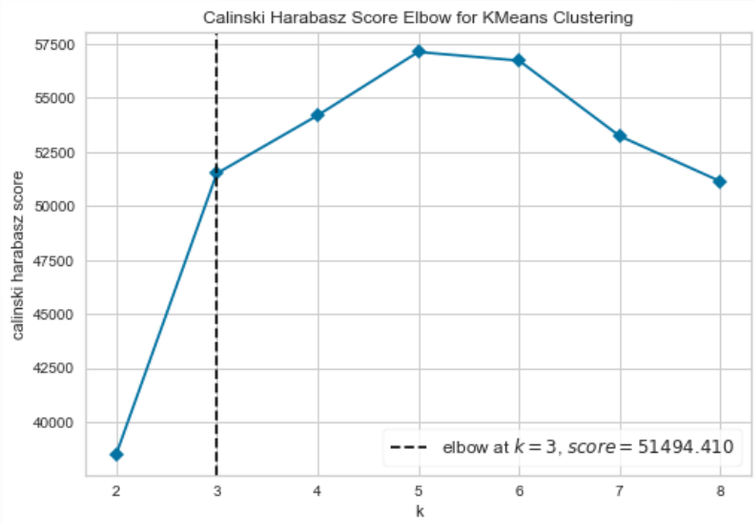

Metriques

Original

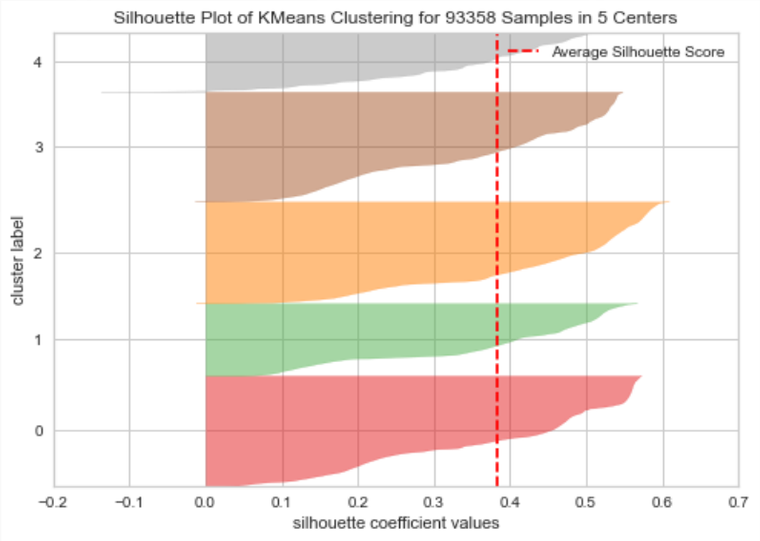

0	45204
4	36932
1	7445
3	2933
2	844

Original

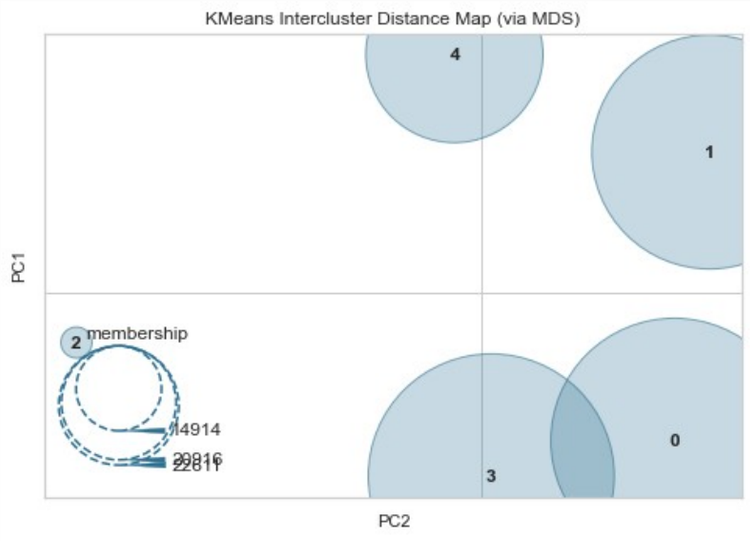

PCA projected (pas besoin de passer par PCA)

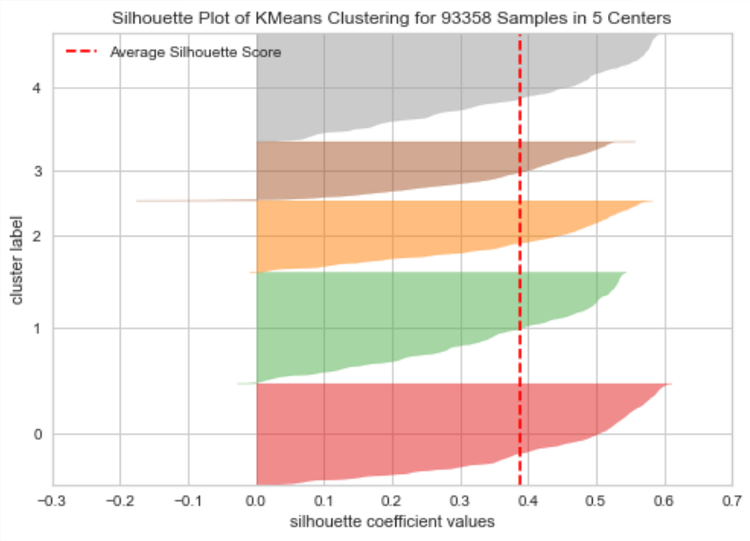

0	45285
1	36978
3	7331
4	2933
2	831

PCA projected

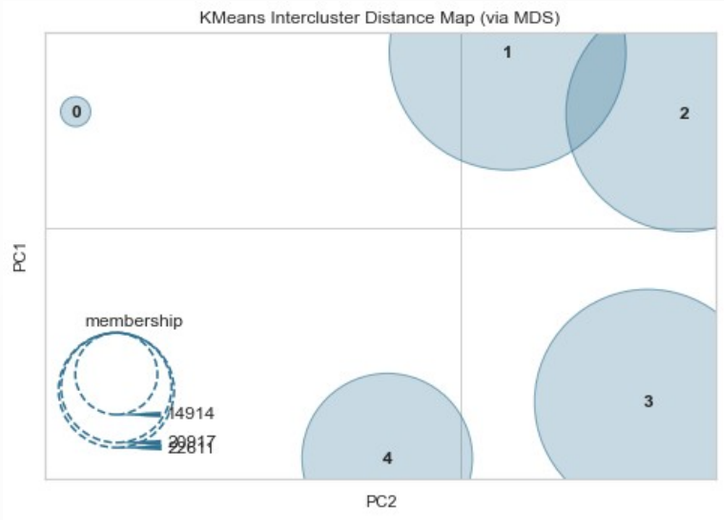

Signification de segments

Original et PCA projected
ont les mêmes paramètres

Les traits distinctives
des membres de chaque segment
sont présentées
dans le diapositif suivant

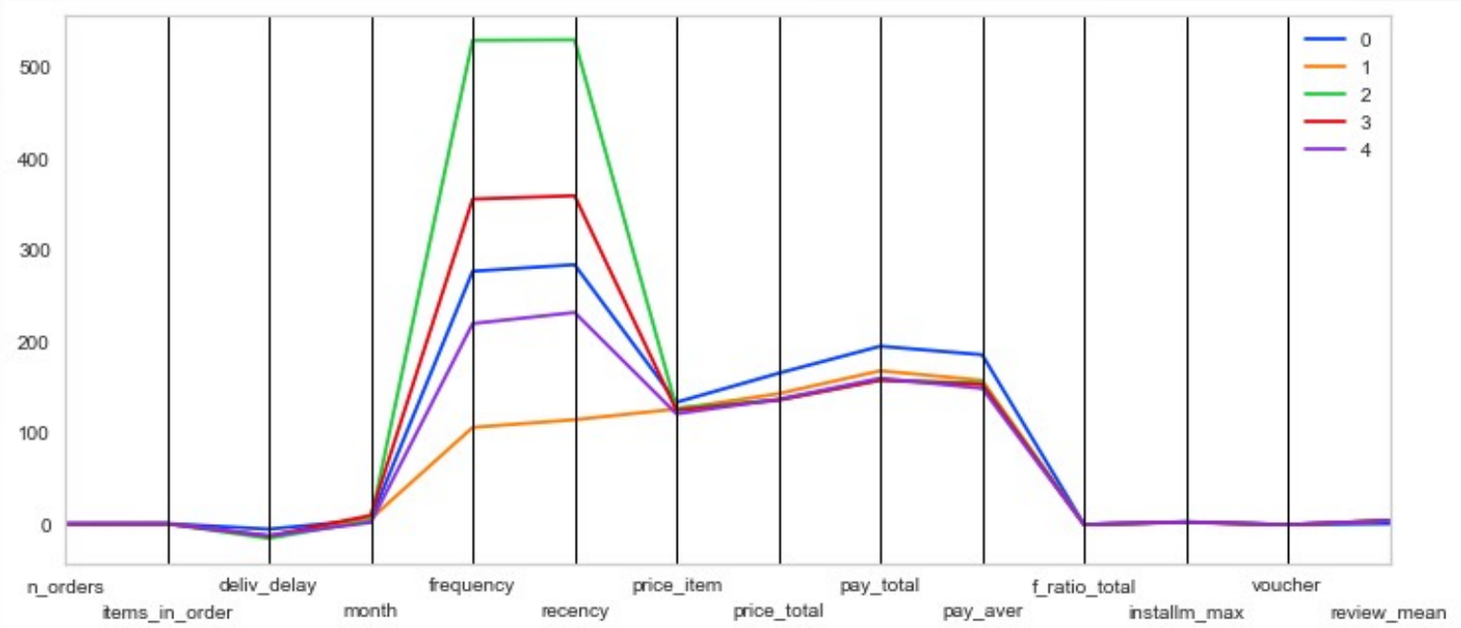

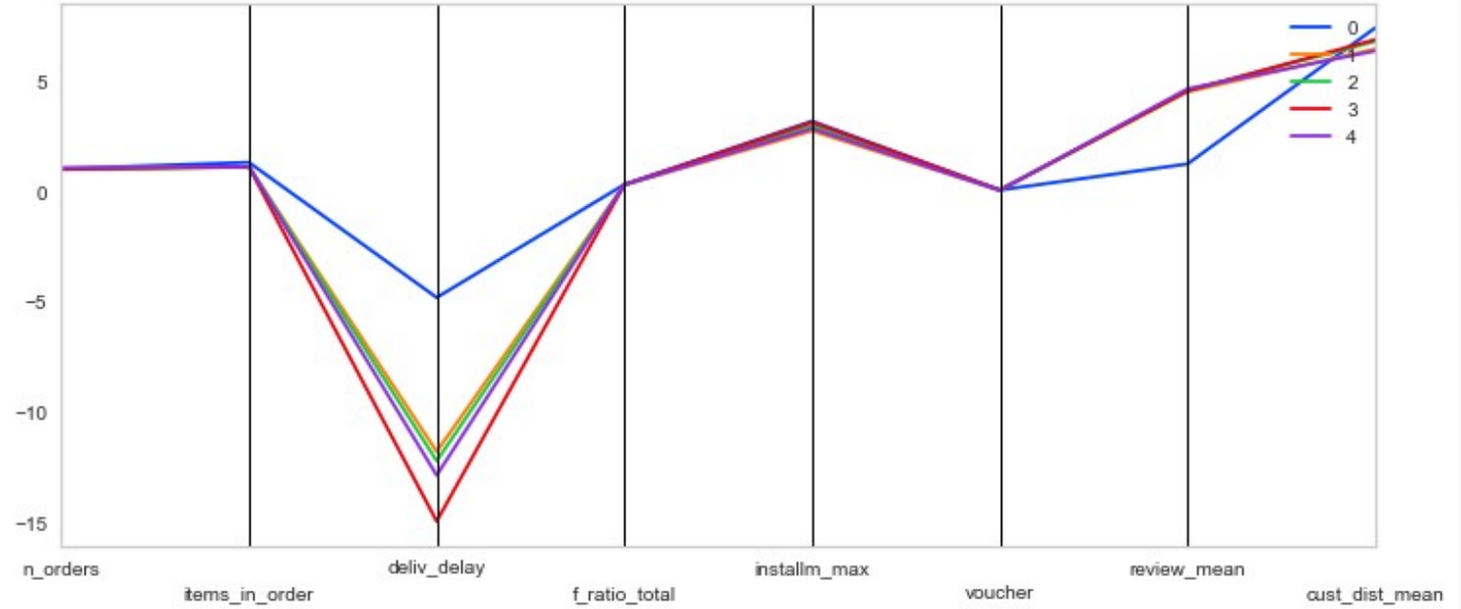

Signification des segments

- Paradoxalement, MinMaxScaler a des meilleurs métriques parmi les algorithmes téstés, mais la déscription qu'on peut ressortir, n'est pas très utile.
- 0 : Clients d'ancienneté moyenne, en moyen 300 jours. Depensent **legèrement plus que les autres** (180 contre 150). Ils ont **les retards de livraison plus importants que les autres** (-2 jours contre -16). Ils ont **laissé de mauvais avis** (1,6 contre 4,8).
- 1 : Clients **les plus récents et fréquents** (environ 100 jours).
- 2 : Clients **très anciens et très rares**, plus de 400 jours.
- 3 : Clients anciens et rares, plus de 300 jours.
- 4 : Clients relativement recents et frequents (220 jours).

Comparaison de MinMax scaler et StandardScaler

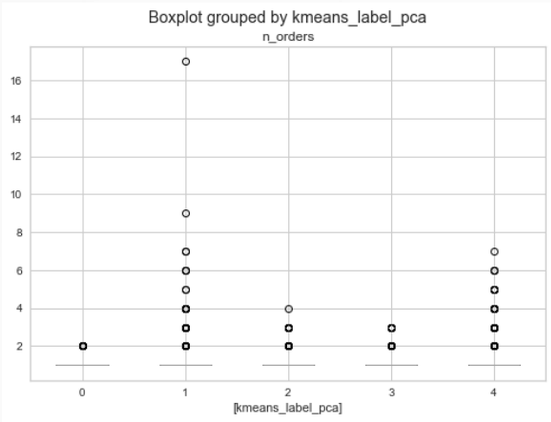

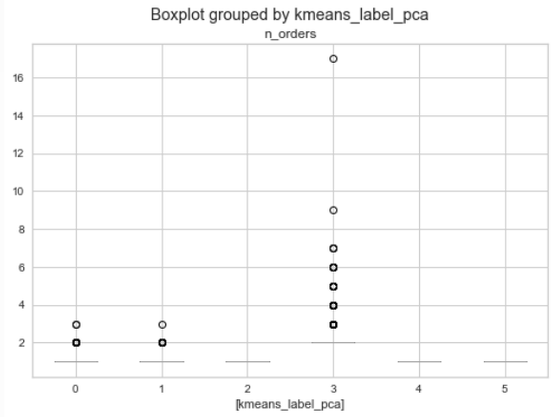

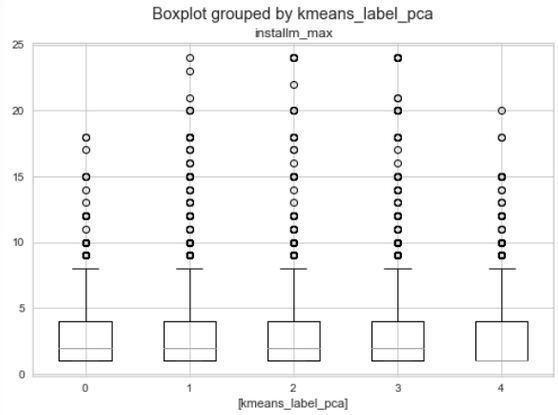

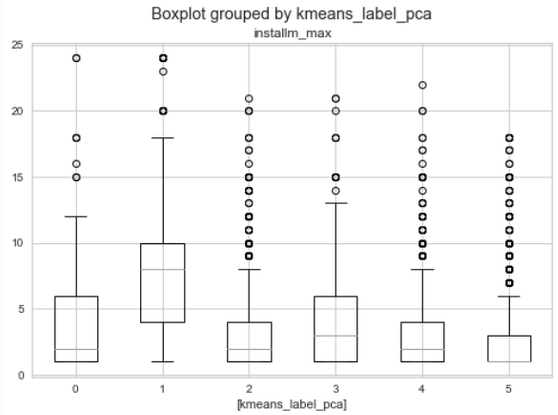

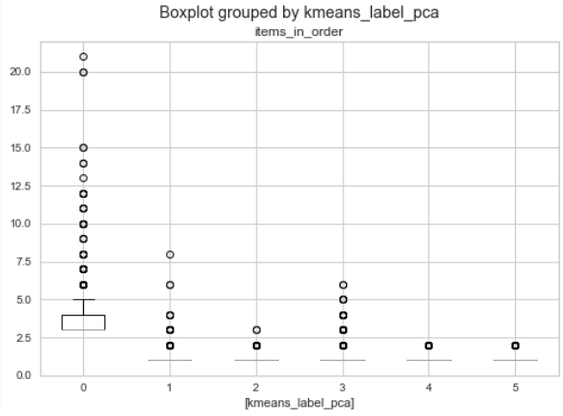

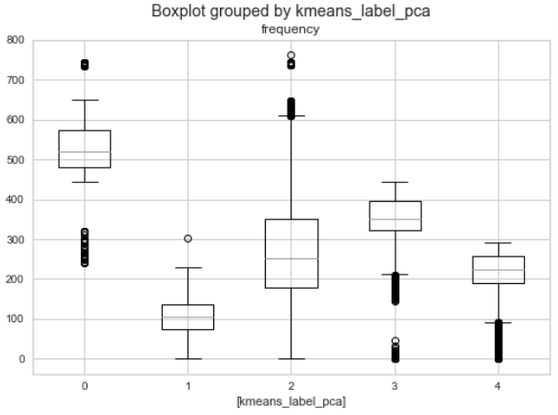

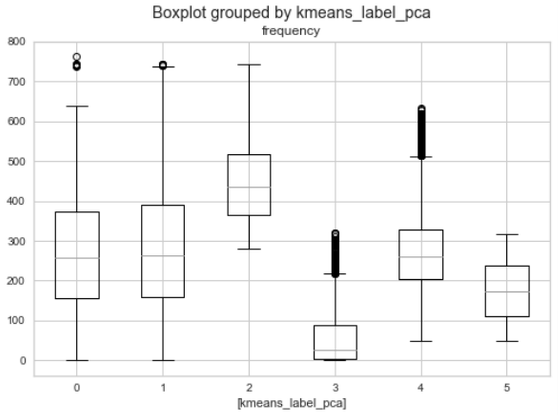

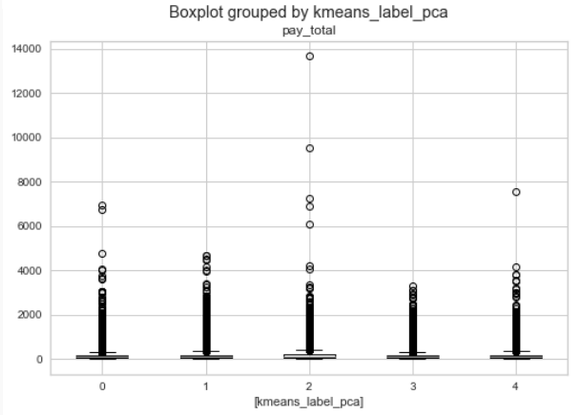

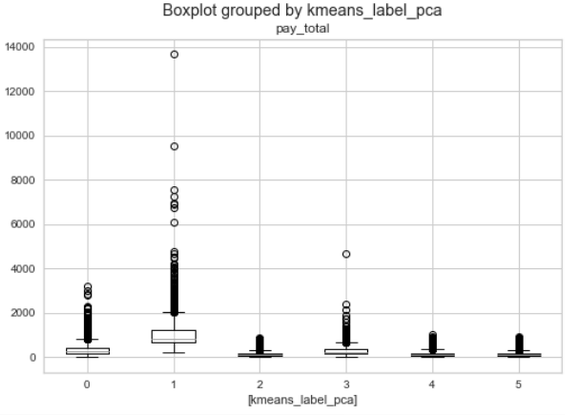

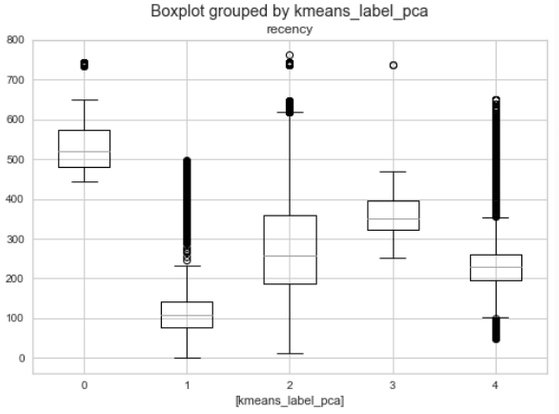

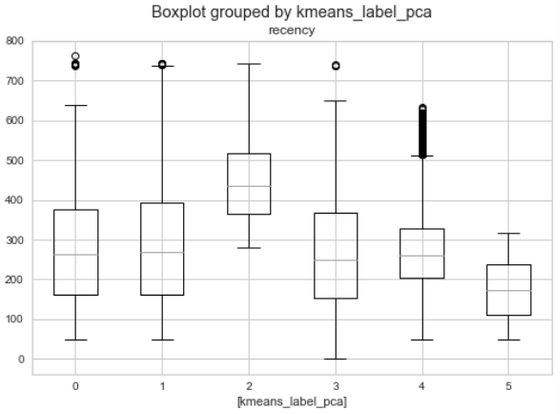

Segmentation hierarchique

- Agglomerative clustering (bottom-up)

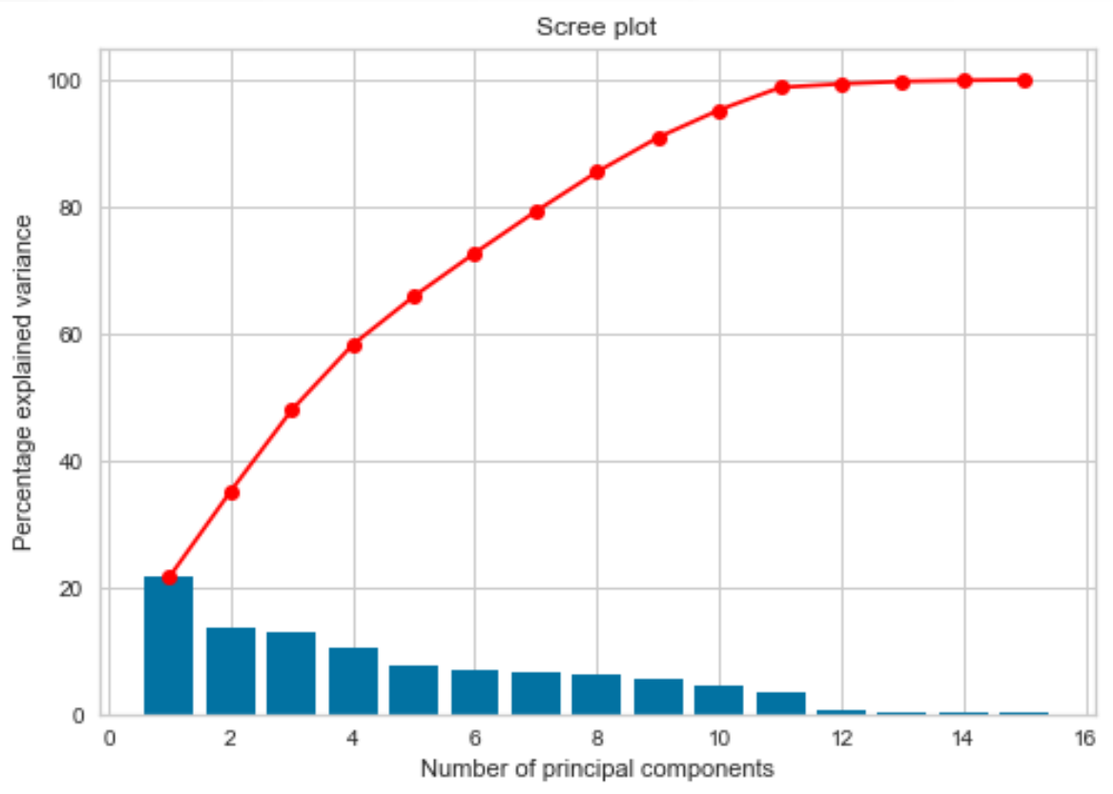

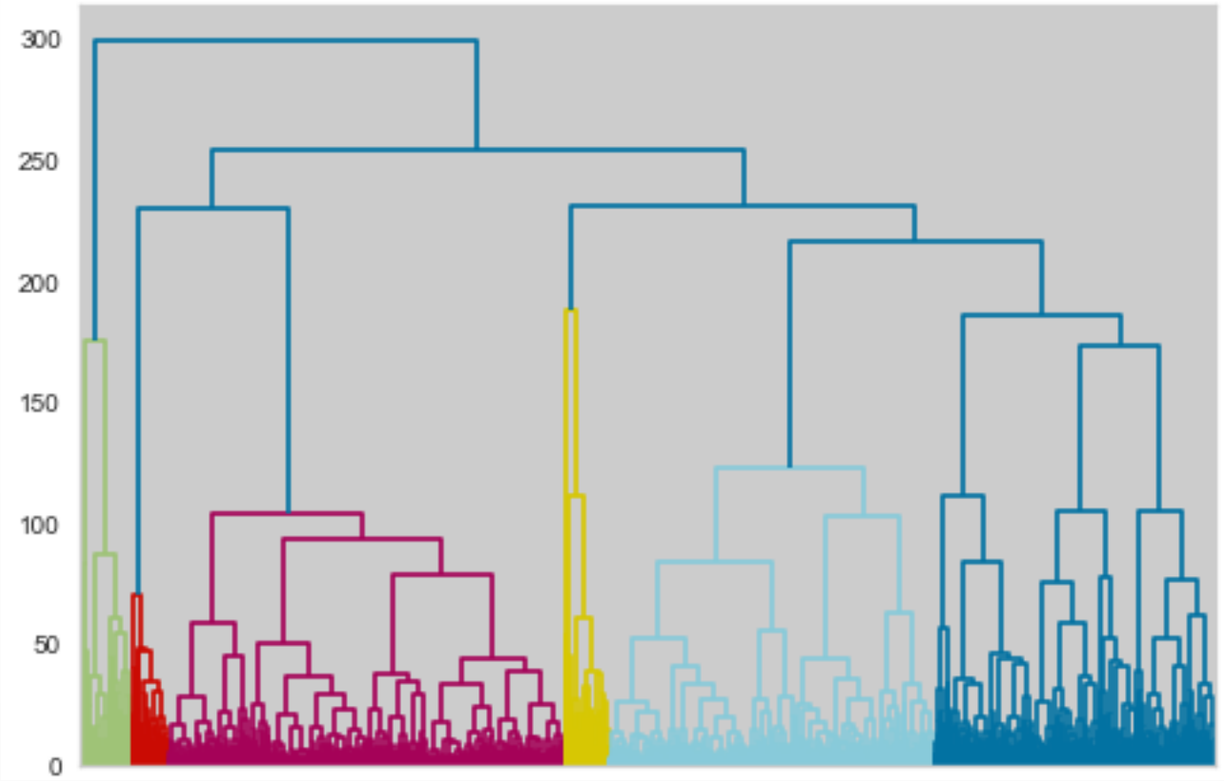

Sens de clusters

Agglomerative clustering

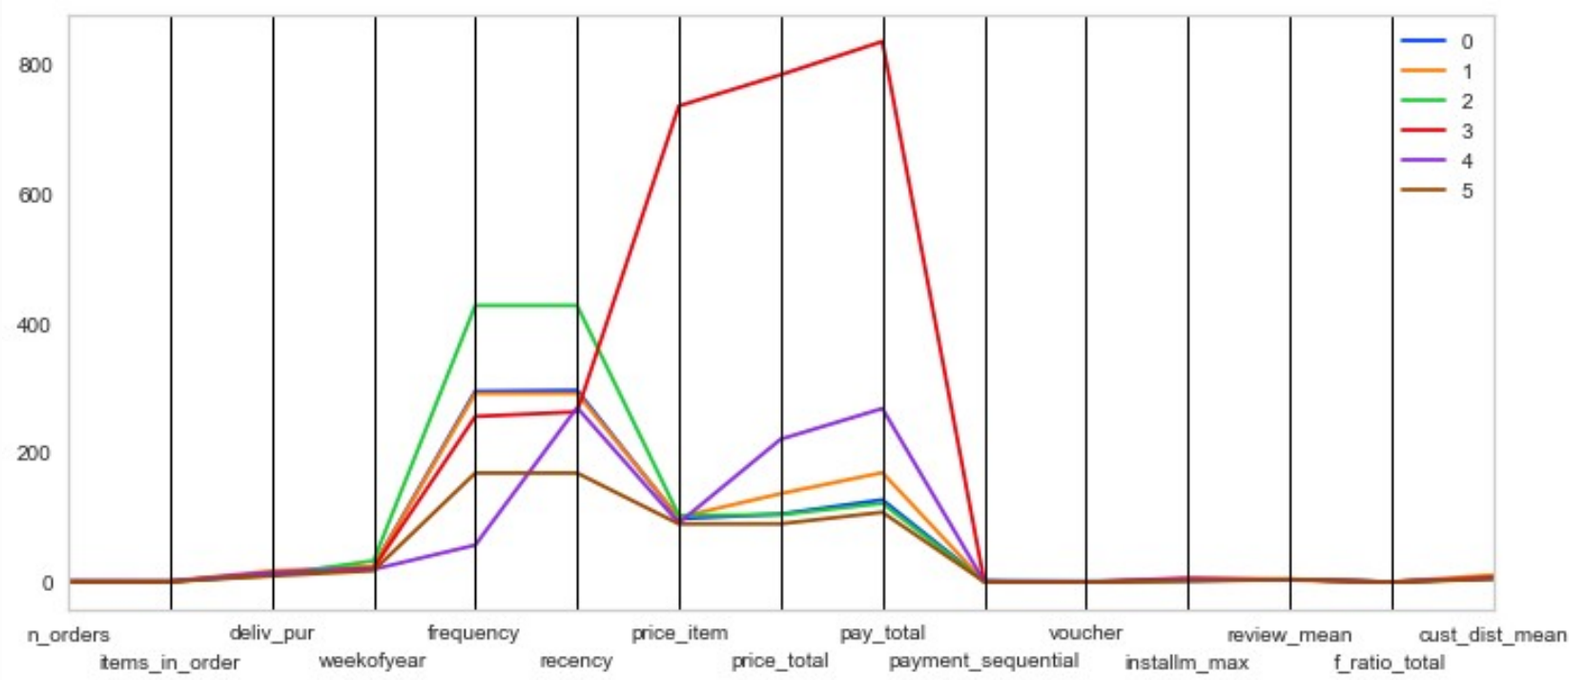

KMeans
Avec StandardScaler
(reference)

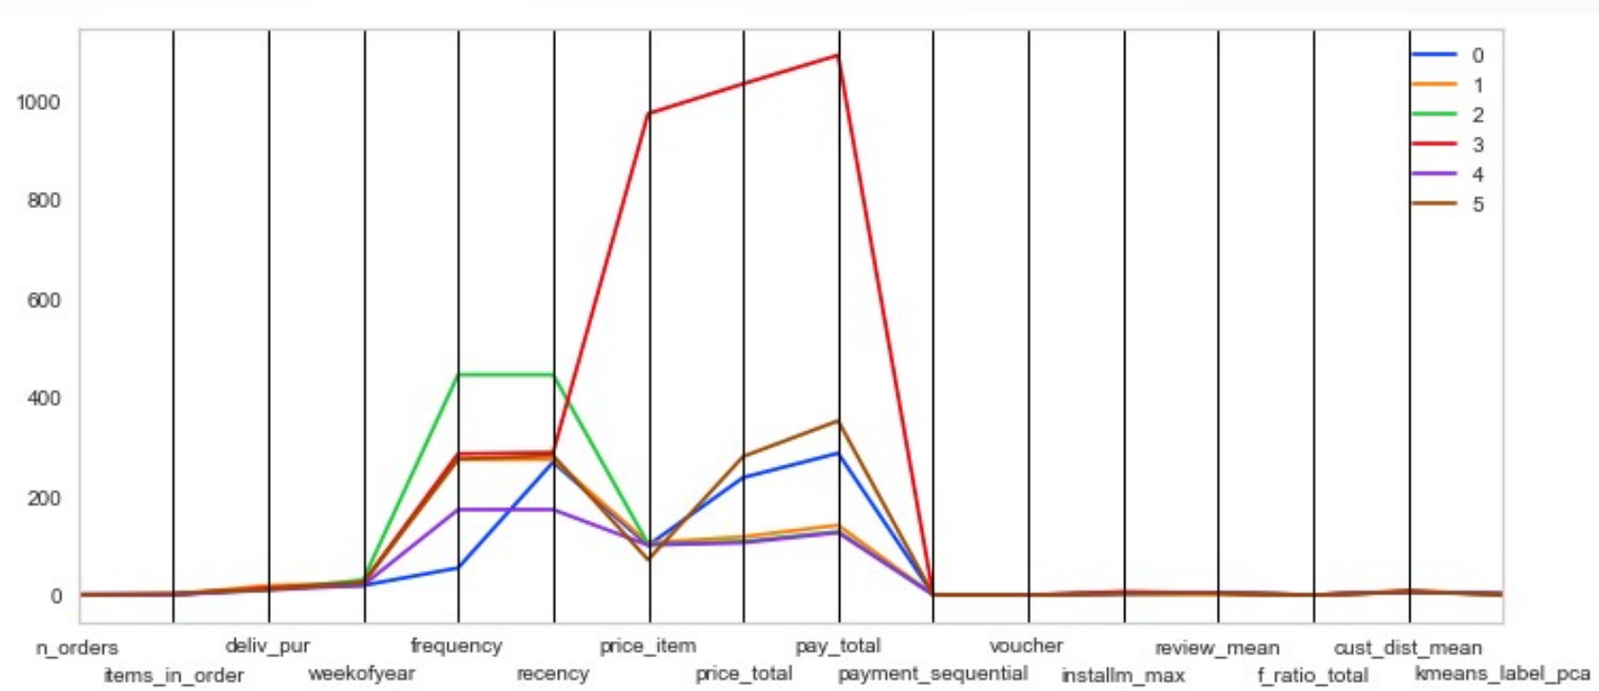

Sens de clusters, mis apart les variables le plus étendues

Agglomerative clustering

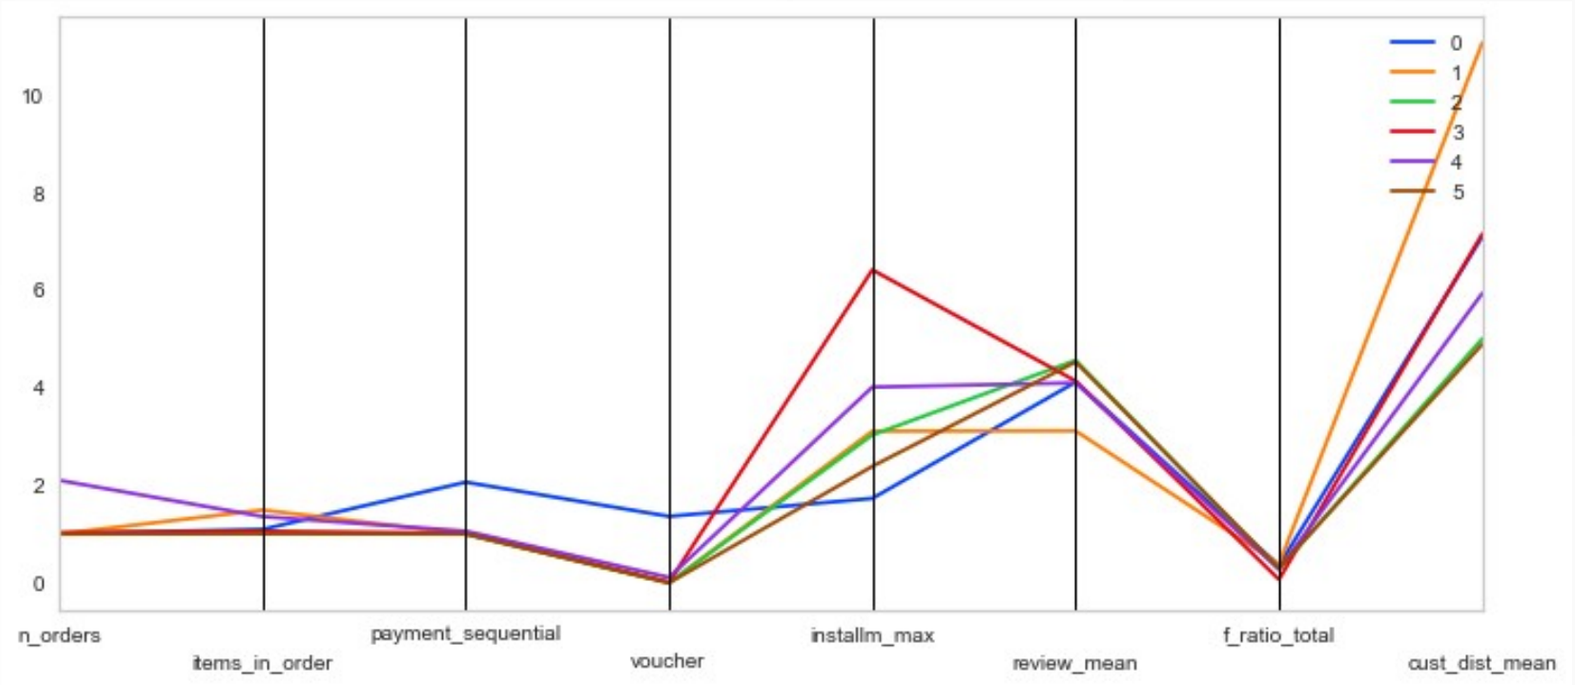

KMeans
Avec StandardScaler
(reference)

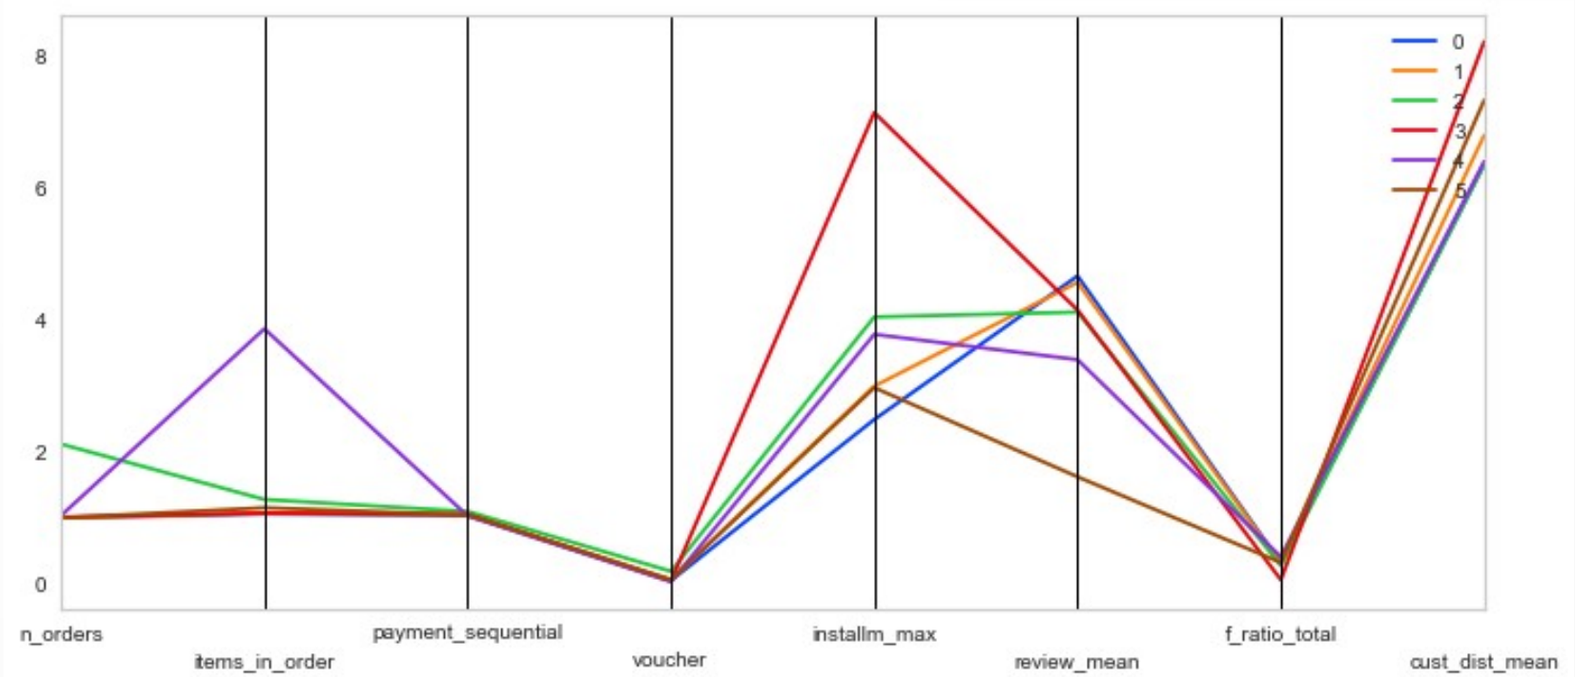

Signification des segments

- En plupart la segmentation hiérarchique ressemble à celle avec Kmeans et StandardScaler avec l'espace de variables réduit.
- La difference entre ses segmentations : avec la segmentation hiérarchique, nous voyons qu'il y a un group « amateurs de bons de réductions », qui les utilisent beaucoup.

Gaussian mixture (5 segments)

- 0 : Clients anciens et rares, qui achètent des articles un peu chers (300 réals en moyen)
- 1 : clients dormants : fréquents (100 jours, mais pas si récents (180 jours). Ils dépensent des sommes moyens (300 réals), mais achetent des artciles largement moins chers que de clients de segment 0 (180 réals contre 300)
- 2 : Clients d'ancienneté moyenne (300 jours), qui ont dépensé beaucoup (près de 500 réals) et ont payé en moyen 570 réals.
- 3 : Clients anciens et rares, qui achètent des articles peu couteux
- 4 : Clients les plus récents (170 jours en moyen) mais pas si fréquents : ils ont fait 1 ordre seulement.

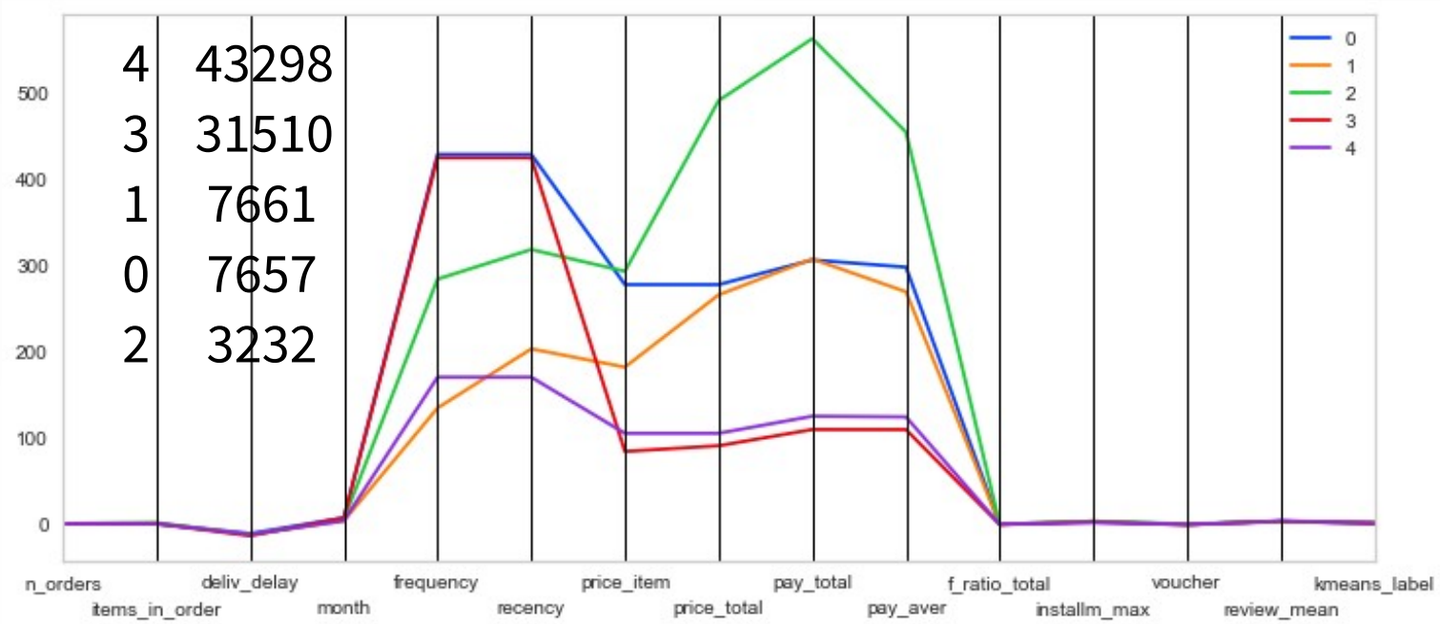

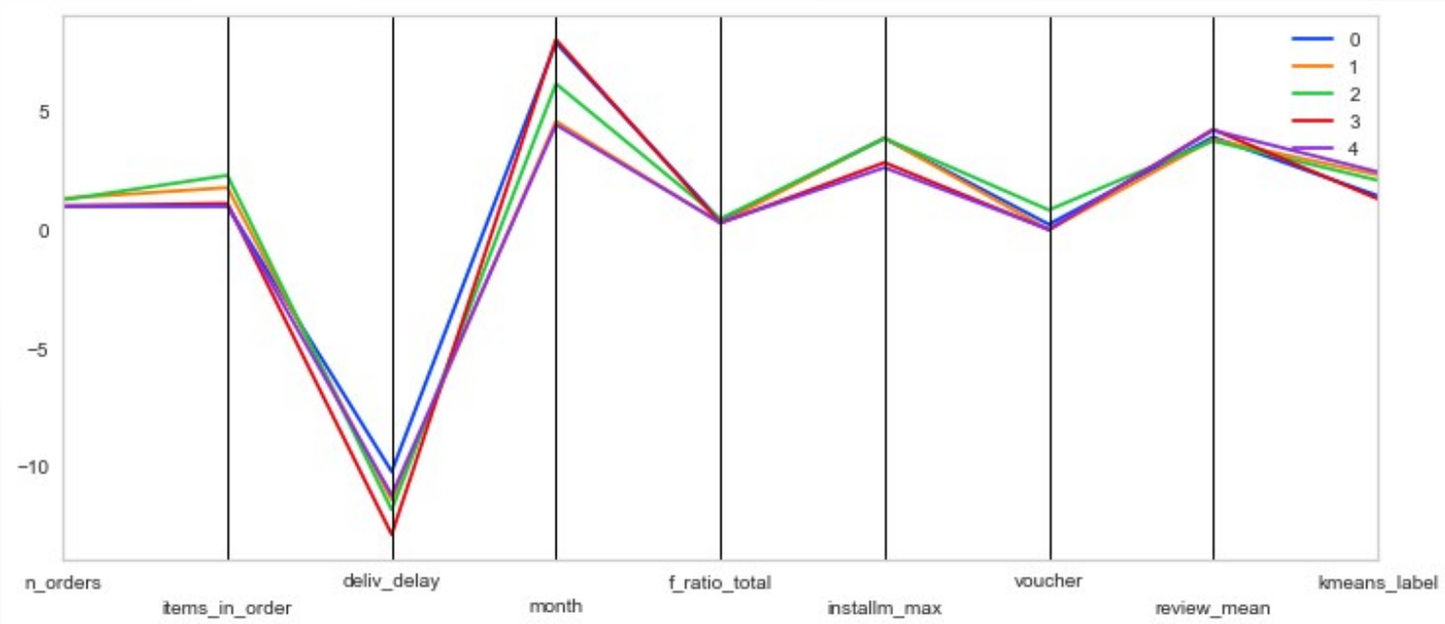

Gaussian mixture (6 segments)

- 0 : Clients les plus récents (170 jours en moyen) mais pas si fréquents : ils ont fait 1 ordre seulement.
- 1 : Clients avec la fréquence et la récence moyennes : 200 jours et 250 jours. Ils dépensent des sommes moyens (300 réals), mais achetent des artciles largement moins chers que de clients de segment 0 (180 réals contre 300)
- 2 : Clients anciens et rares, qui achètent des articles assez chers (300 réals en moyen) et dépensent un peu plus (400 réals).
- 3 : clients dormants : fréquents (100 jours, mais pas si récents (180 jours). Ils achètent des articles un peu chers (300 réals en moyen) et dépensent un peu plus (400 réals).
- 4 : Clients anciens et rares, qui achètent des articles peu chers (120 réals en moyen) et dépensent peu (120 réals). Ils ont fait seulement un ordre.
- 5 : clients d'ancienneté moyenne, qui ont dépensé tout aussi peu comme les clients de segment 4.

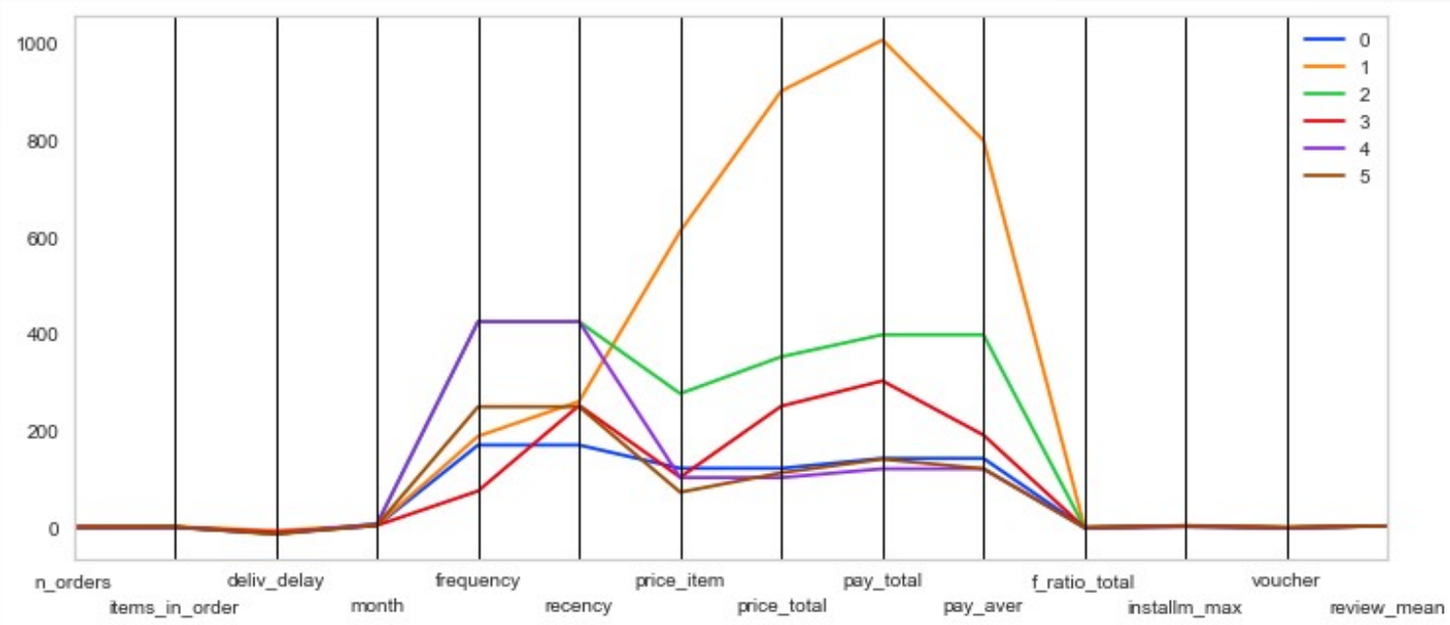

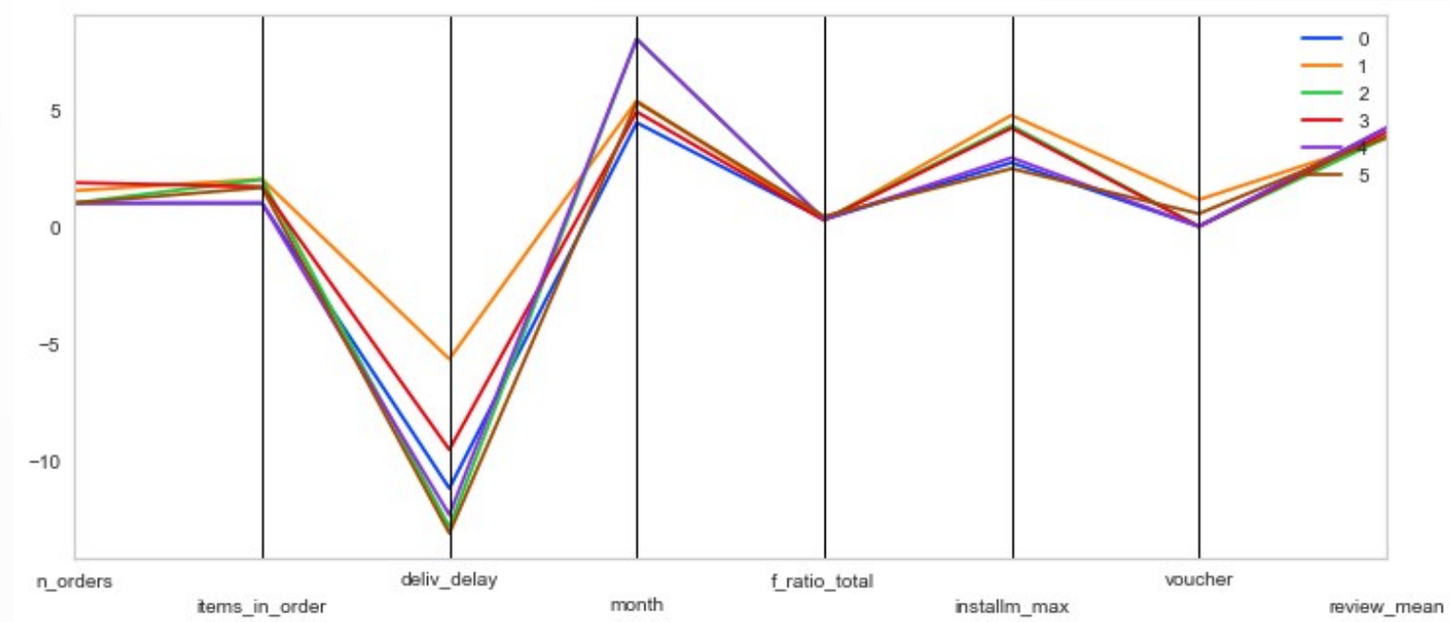

Comparaison des algorithmes avec des métriques standartes

Kmeand, StandardScaler, Full set	4	5	6	7
Silhouette * 10	2,177	2,308	2,337	2,126
Calinski-Harabasz	14957	14438	13796	13214
Davies-Bouldin	1,451	1,391	1,380	1,420

Kmeans, MinMaxScaler	4	5	6	7
Silhouette * 10	2,292	2,310	2,084	2,126
Calinski-Harabasz	15547	14438	13512	13214
Davies-Bouldin	1,418	1,389	1,452	1,420

Kmeans, StandardScaler, Reduced Set	4	5	6	7
Silhouette * 10	2,875	3,120	3,215	3,306
Calinski-Harabasz	21873	22549	22951	23760
Davies-Bouldin	1,153	1,142	1,030	1,020

Gaussian	4	5	6	7
Silhouette * 10	1,813	1,912	1,933	1,934
Calinski-Harabasz	8095	6668	6666	5519
Davies-Bouldin	2,364	2,509	2,197	2,524

Stabilité temporelle de la segmentation, fenêtre en expansion

- Regarder sur le clients de premiers 12 mois et regarder à quel moment ils changent de cluster, a l'aide de Adjusted Rand Index
- Créer le jeu de donner sur 12 mois initial, sauvegarder les idéntifiants des clients ;
- Créer le jeu de donnér sur 14 mois, sélectionner uniquement les clients initiaux, calculer le ARI entre ces mêmes clients après 12 mois et 14 mois (vois la différence dans 2 mois);
- Idem pour 16 mois (dans 4 mois), 18 mois (dans 6 mois) … jusq'au dernier ordre livré.
- ARI est près de 0,9 dans 2 mois et dans 4 mois, puis il tombe dans 6 mois.
- Avec des « random state » différents pour s'assurer que le résultat est stable

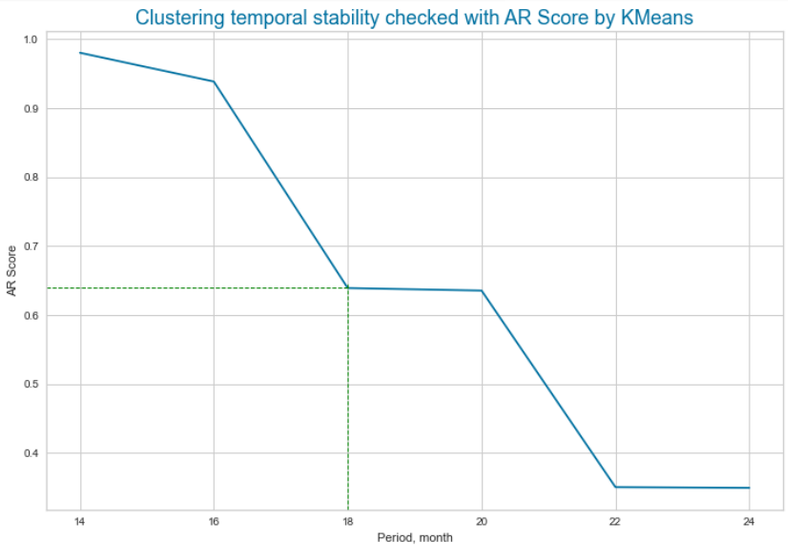

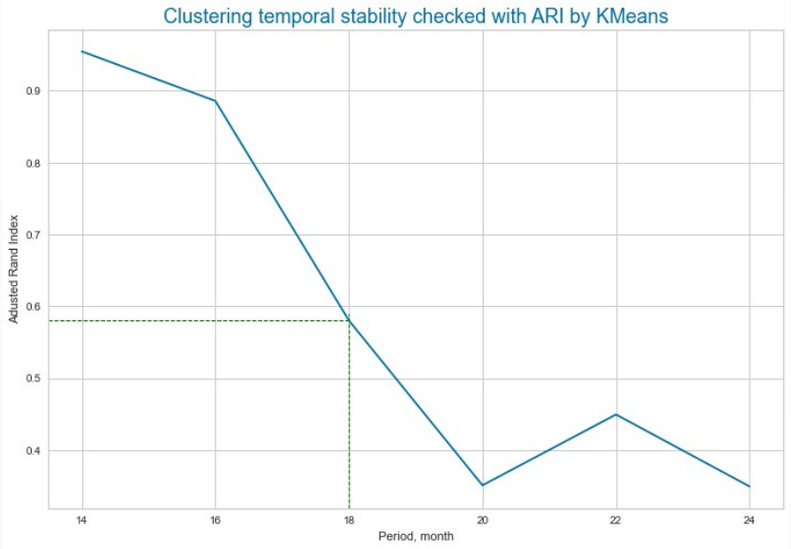

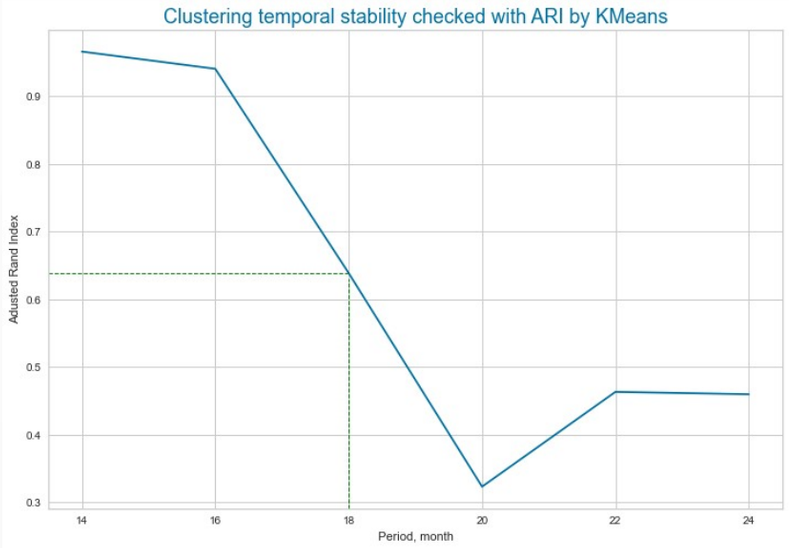

Stabilité temporelle de la segmentation, fenêtre glissante

- Ajuster la taille de l'ordre glissante et la taille d'ensemble refentielle des clients (au milieu de la période totale d'observations):
  - Que la taille de la fenêtre glissante et au moins 12 mois ;
  - Que la taille de l'ensemble clients referentiels est au moins 10,000 clients ;
  - Que la période d'observations est au moins 10 mois, voire 12;
  - Que la période entre les prise d'observations soit au maximum 2 mois, moins c'est mieux c'est. Ici la containte est le temps de calcul si nous prenons les mésures trop souvent.

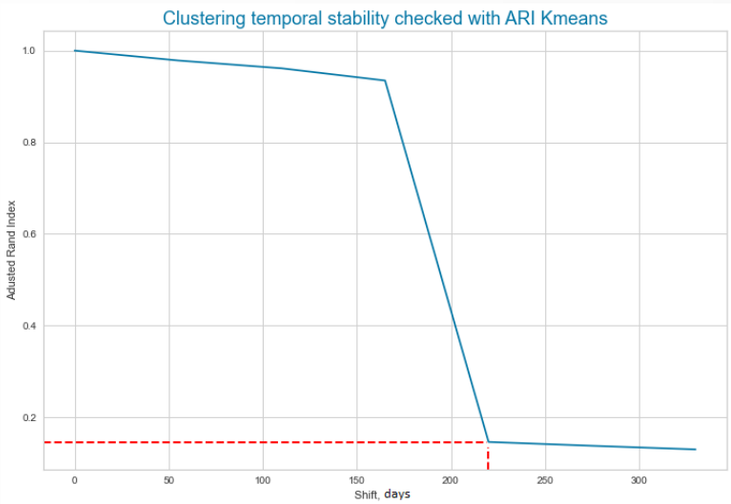

- Les paramètres sélectionnés : la taille de la fenêtre 440 jours, l'ensemble de clients est 13837 personnes, 7 mésures sont prises avec décalage de 55 jours (ce qui donne 330 jours d'observation d'évolution)
- ARI est près de 0,9 dans 2 mois et dans 4 mois, puis il tombe dans 220 jours.
- Avec des « random state » différents pour s'assurer que le résultat est stable (souvent l'image identique)

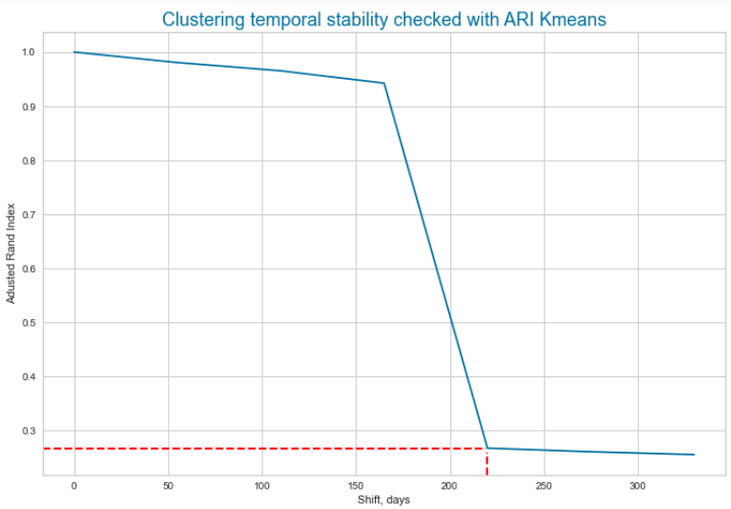

Stabilité temporelle

- La déclinaison de stabilité est bien visible avec la segmentation avec MinMaxScaler, dont la description n'est pas actionnable.
- Par contre, avec segmentation ave StandardScaler et l'espace de variables réduit, que je trouve la meilleure en tèrmes de claréte et l'utilité de la description, la stabilité temporelle diminue juste un petit peu en 12 mois, typiquement de 0,9 à 0,8 AR Index.
  Et définir un délais temporel fait partie essentielle de ma mission.
- Un bon compromis peut devenir la segmentation Kmeans avec écailleur StandardScaler. Elle a la description des clients satisfaisante, et la stabilité temporelle qui dure 10 mois, puis tombe significativement.

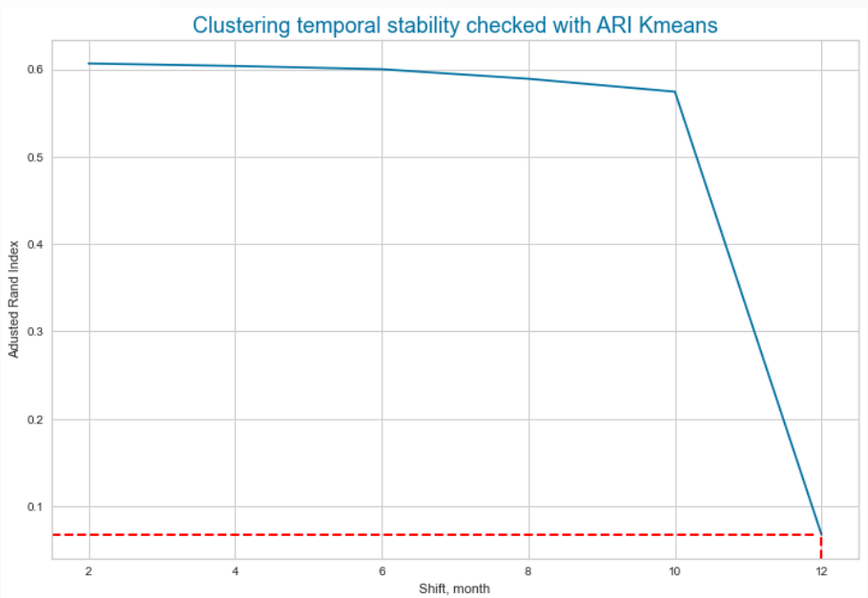

Conclusion :

- La segmentation de la clientelle était fait à l'aide des algorithmes de la segmentation : K-Means et Gaussian Mixture, qui marchent sur notre jeu de données, et Agglomerative Clustering, qui demande soit grande éspace mémoire, soit ne peut être effectué que sur une partie de jeu de donnés.
- L'impact de écailleur (StandardScaler ou MinMaxScaler) était investigué pour K-Means : visualisations de Silhouettes et Intercluster Distance sont mieux pour MinMaxScaler, tandis que la description des clusters est plus actionnable avec StandardScaler. Nous voyons aussi avec les graphiques de distribution (boxplot) que la séparation de clients est plus importante avec StandardScaler et nombre de variable reduit, que avec MinMaxScaler.
- Les métriques SilhouetteScore, Calinski-Harabasz, Davies-Bouldin sont les meilleurs avec Kmeans qui utilise StandardScaler et le nombre de variables réduit.
- Stabilité temporelle était mésurée avec la fenêtre en expansion et la fenêtre glissante, pour tous les algorithmes
  - La fenêtre en expansion marche le mieux avec Kmeans avec MinMaxScaler : la stabilité tient bien 2 et 4 mois, mais tombe grave dans 6 mois. Kmeans avec StandardScaler et l'espace de variables réduit et 4 clusters tient stable jusqu'à 10 mois, puis tombe dans 12 mois. Avec de 5 à 7 clusters le ARI ne tombe pas plus bas que 0,7.
  - La fenêtre glissante marche bien pour Kmeans et l'espace de variables reduit et de 4 à 6 clusters : le ARI tient haut à 165 jours, puis tombe à 220 jours
- **Il est donc recommandé d'utiliser le Kmeans avec l'espace de variables réduit, et faire la maintenance, la mise à jour de la base de clients, dans la périodicité entre 165 et 220 jours – par exemple 6 mois.**